

# 双塔模型+自监督学习

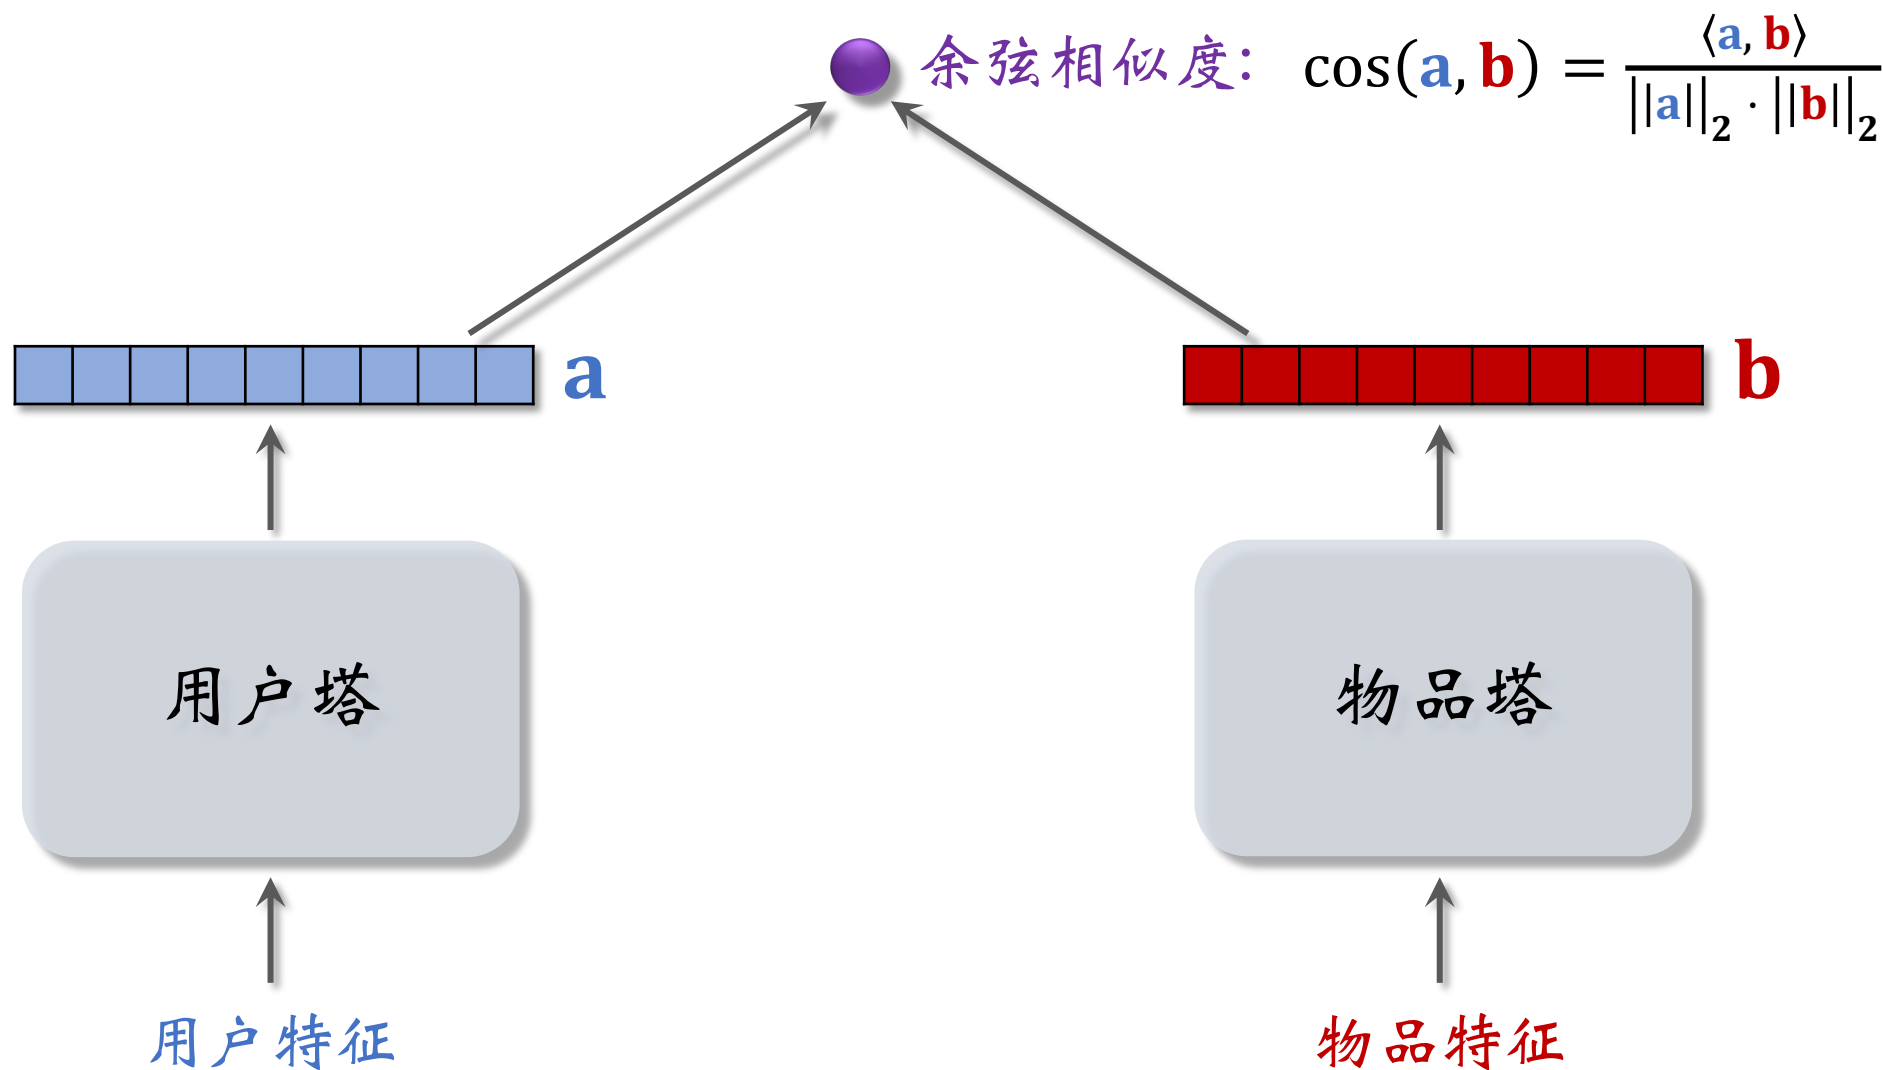
王树森

ShusenWang@xiaohongshu.com

<http://wangshusen.github.io/>



# 双塔模型



# 双塔模型的问题


- 推荐系统的头部效应严重：
  - 少部分物品占据大部分点击。
  - 大部分物品的点击次数不高。
- 高点击物品的表征学得好，长尾物品的表征学得不好。
- 自监督学习：做 data augmentation，更好地学习长尾物品的向量表征。

## 参考文献：

- Tiansheng Yao et al. [Self-supervised Learning for Large-scale Item Recommendations](#). In *CIKM*, 2021.

# 复习：双塔模型的训练

# Batch内负样本



# Batch内负样本

用户:

物品:



点击



点击



正样本

⋮


⋮



点击



# Batch内负样本



- 一个 batch 内有  $n$  对正样本。
- 组成  $n$  个 list，每个 list 中有 1 对正样本和  $n - 1$  对负样本。

# Listwise 训练

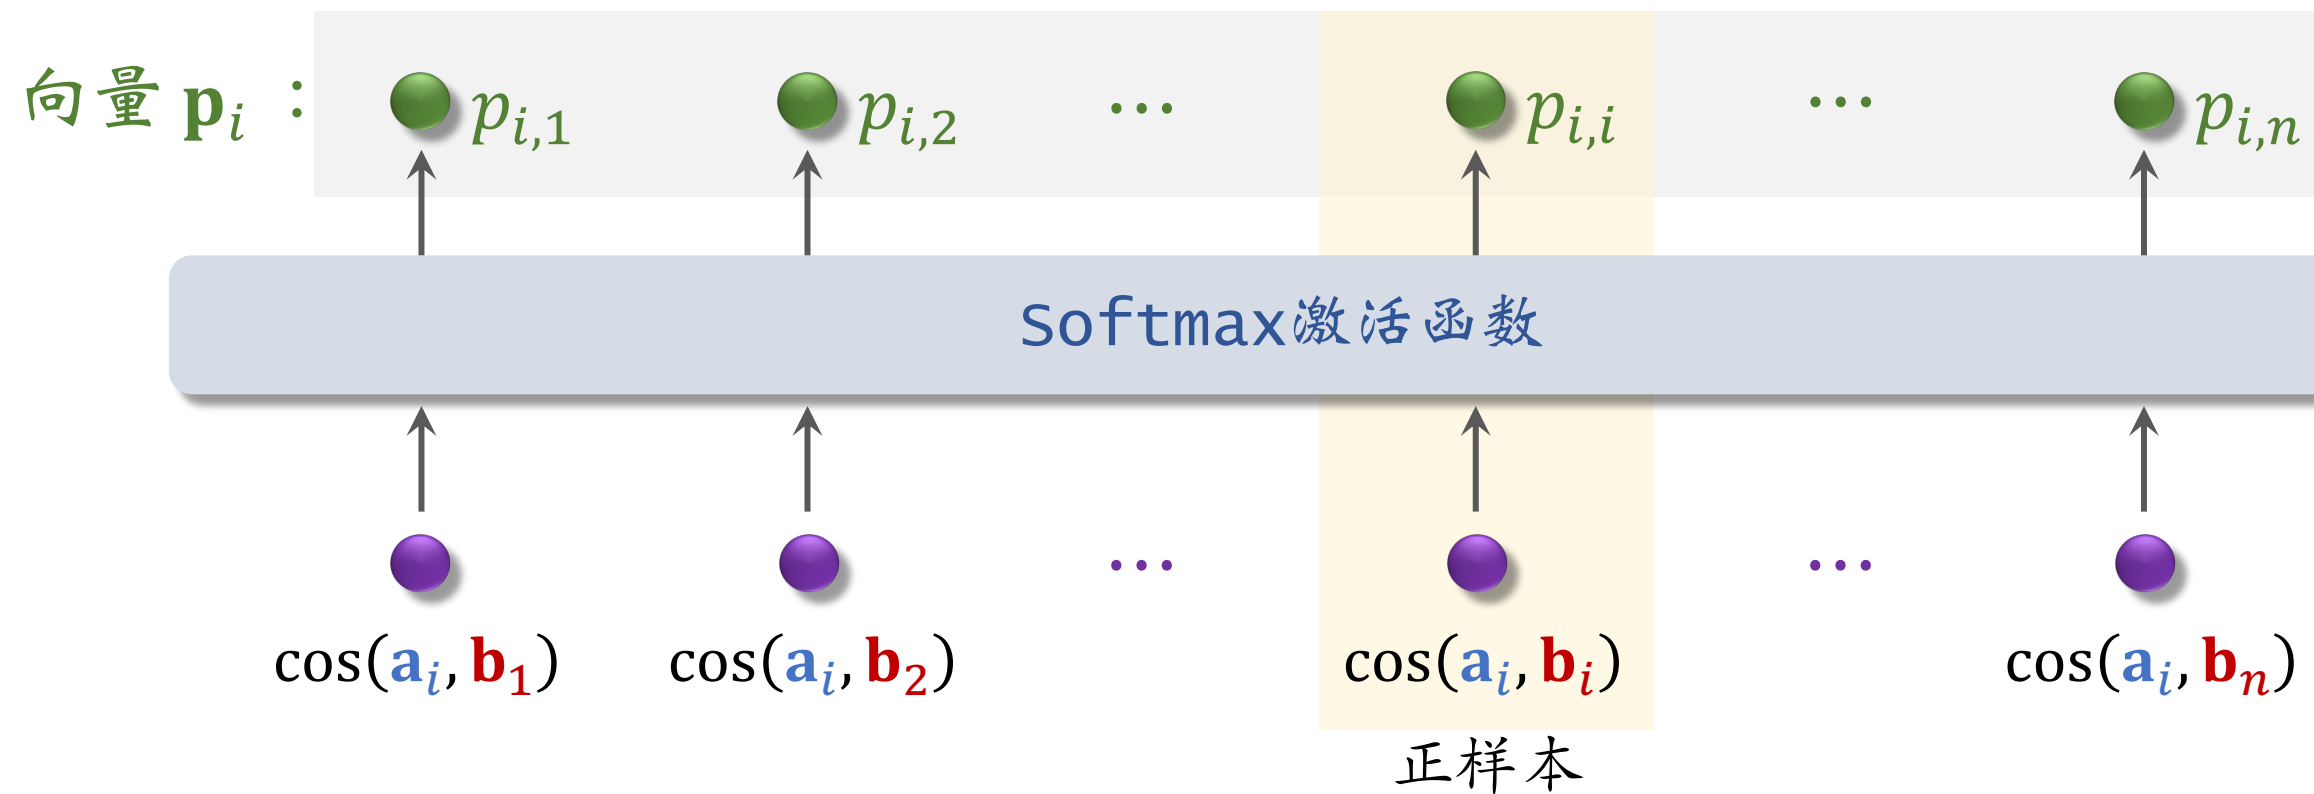
- 一个 batch 包含  $n$  对正样本（有点击）：

$$(\mathbf{a}_1, \mathbf{b}_1), (\mathbf{a}_2, \mathbf{b}_2), \dots, (\mathbf{a}_n, \mathbf{b}_n).$$

- 负样本： $\{(\mathbf{a}_i, \mathbf{b}_j)\}$ ，对于所有的  $i \neq j$ 。
- 鼓励  $\cos(\mathbf{a}_i, \mathbf{b}_i)$  尽量大， $\cos(\mathbf{a}_i, \mathbf{b}_j)$  尽量小。



# 损失函数



# 损失函数

向量  $y_i$  : ● 0      ● 0      ...      ● 1      ...      ● 0

向量  $p_i$  : ●  $p_{i,1}$       ●  $p_{i,2}$       ...      ●  $p_{i,i}$       ...      ●  $p_{i,n}$

Softmax 激活函数

$\cos(\mathbf{a}_i, \mathbf{b}_1)$

$\cos(\mathbf{a}_i, \mathbf{b}_2)$

...


$\cos(\mathbf{a}_i, \mathbf{b}_i)$

...

$\cos(\mathbf{a}_i, \mathbf{b}_n)$

正样本

# 损失函数



# 纠偏

- 物品  $j$  被抽样到的概率：

$$p_j \propto \text{点击次数}$$

- 预估用户  $i$  对物品  $j$  的兴趣： $\cos(\mathbf{a}_i, \mathbf{b}_j)$

- 做训练的时候，把  $\cos(\mathbf{a}_i, \mathbf{b}_j)$  替换为：

$$\cos(\mathbf{a}_i, \mathbf{b}_j) - \log p_j$$

参考文献：

- Xinyang Yi et al. [Sampling-Bias-Corrected Neural Modeling for Large Corpus Item Recommendations](#). In *RecSys*, 2019.

# 训练双塔模型

- 从点击数据中随机抽取  $n$  个用户—物品二元组，组成一个 batch。
- 双塔模型的损失函数：

$$L_{\text{main}}[i] = -\log \left( \frac{\exp(\cos(\mathbf{a}_i, \mathbf{b}_i) - \log p_i)}{\sum_{j=1}^n \exp(\cos(\mathbf{a}_i, \mathbf{b}_j) - \log p_j)} \right).$$

对应用户  $i$

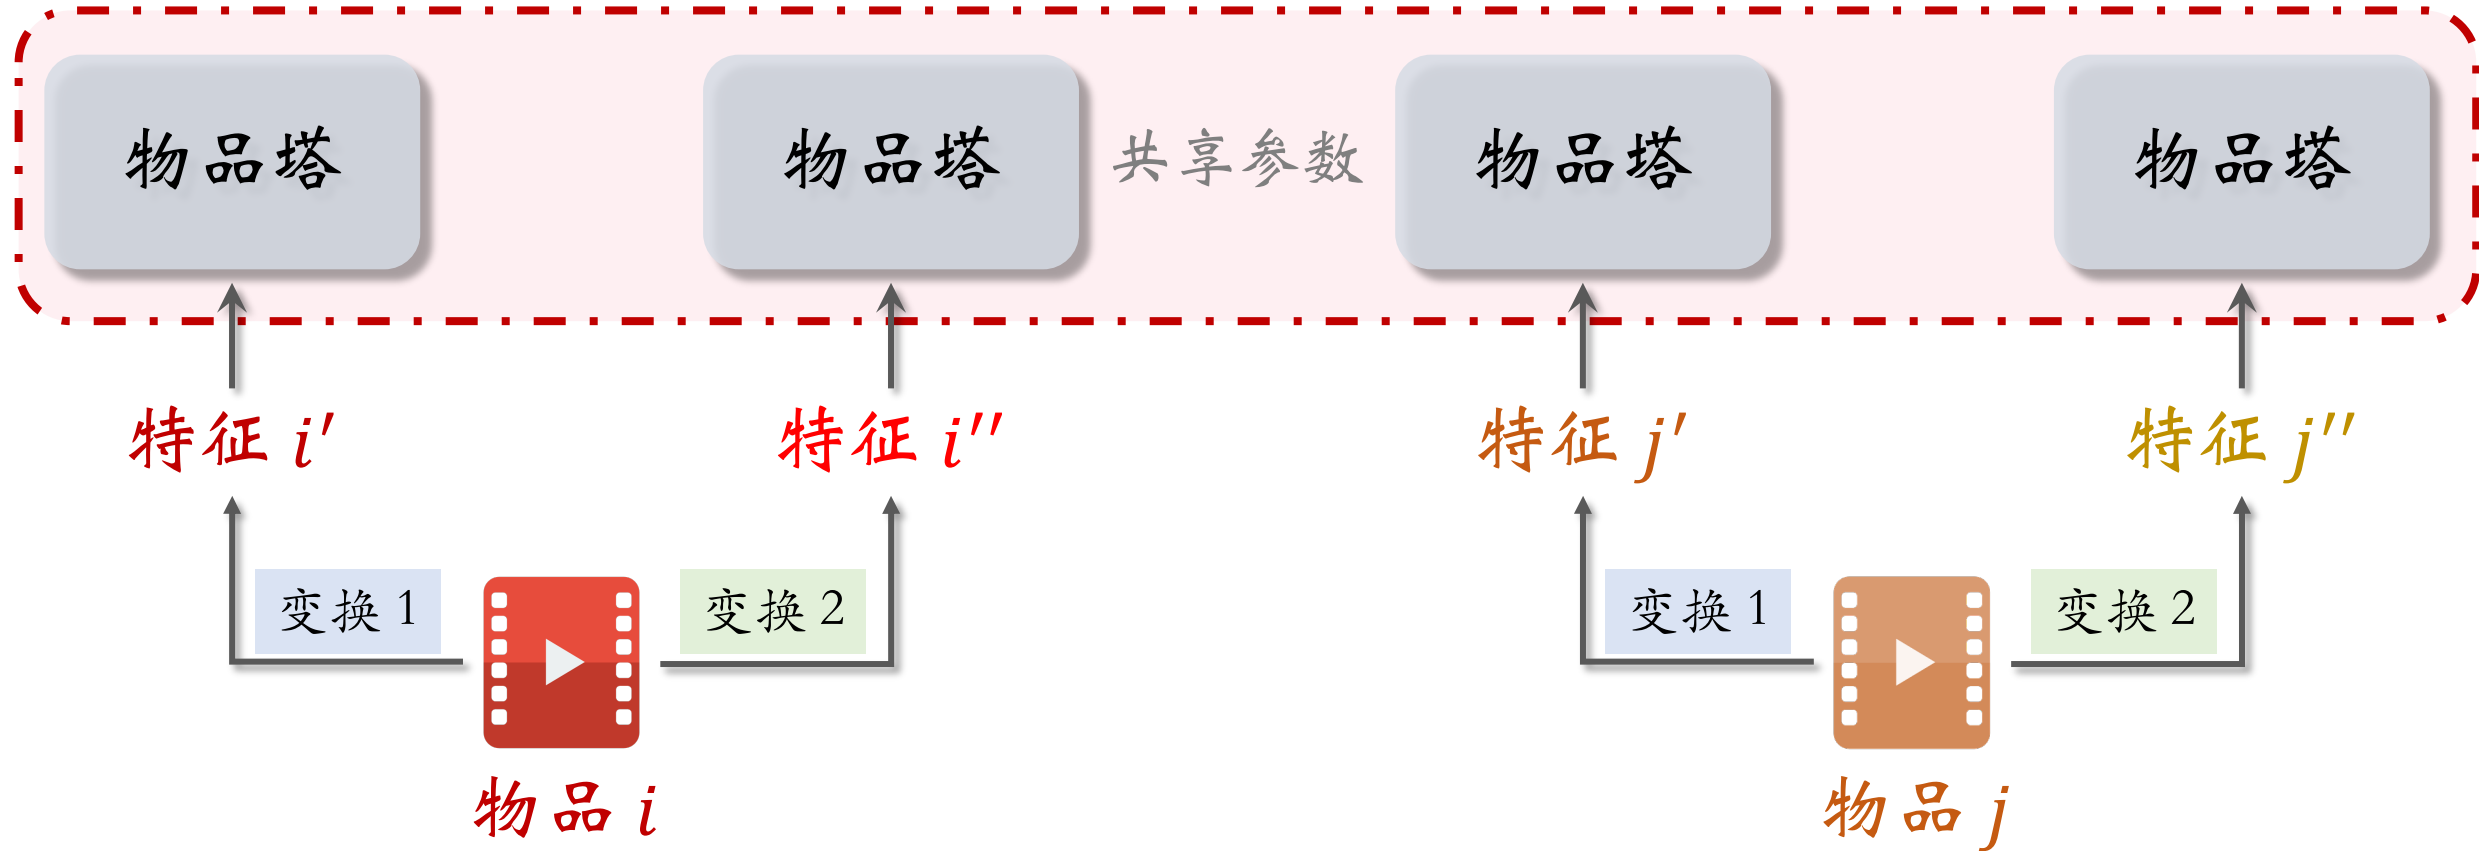
- 做梯度下降，减小损失函数：

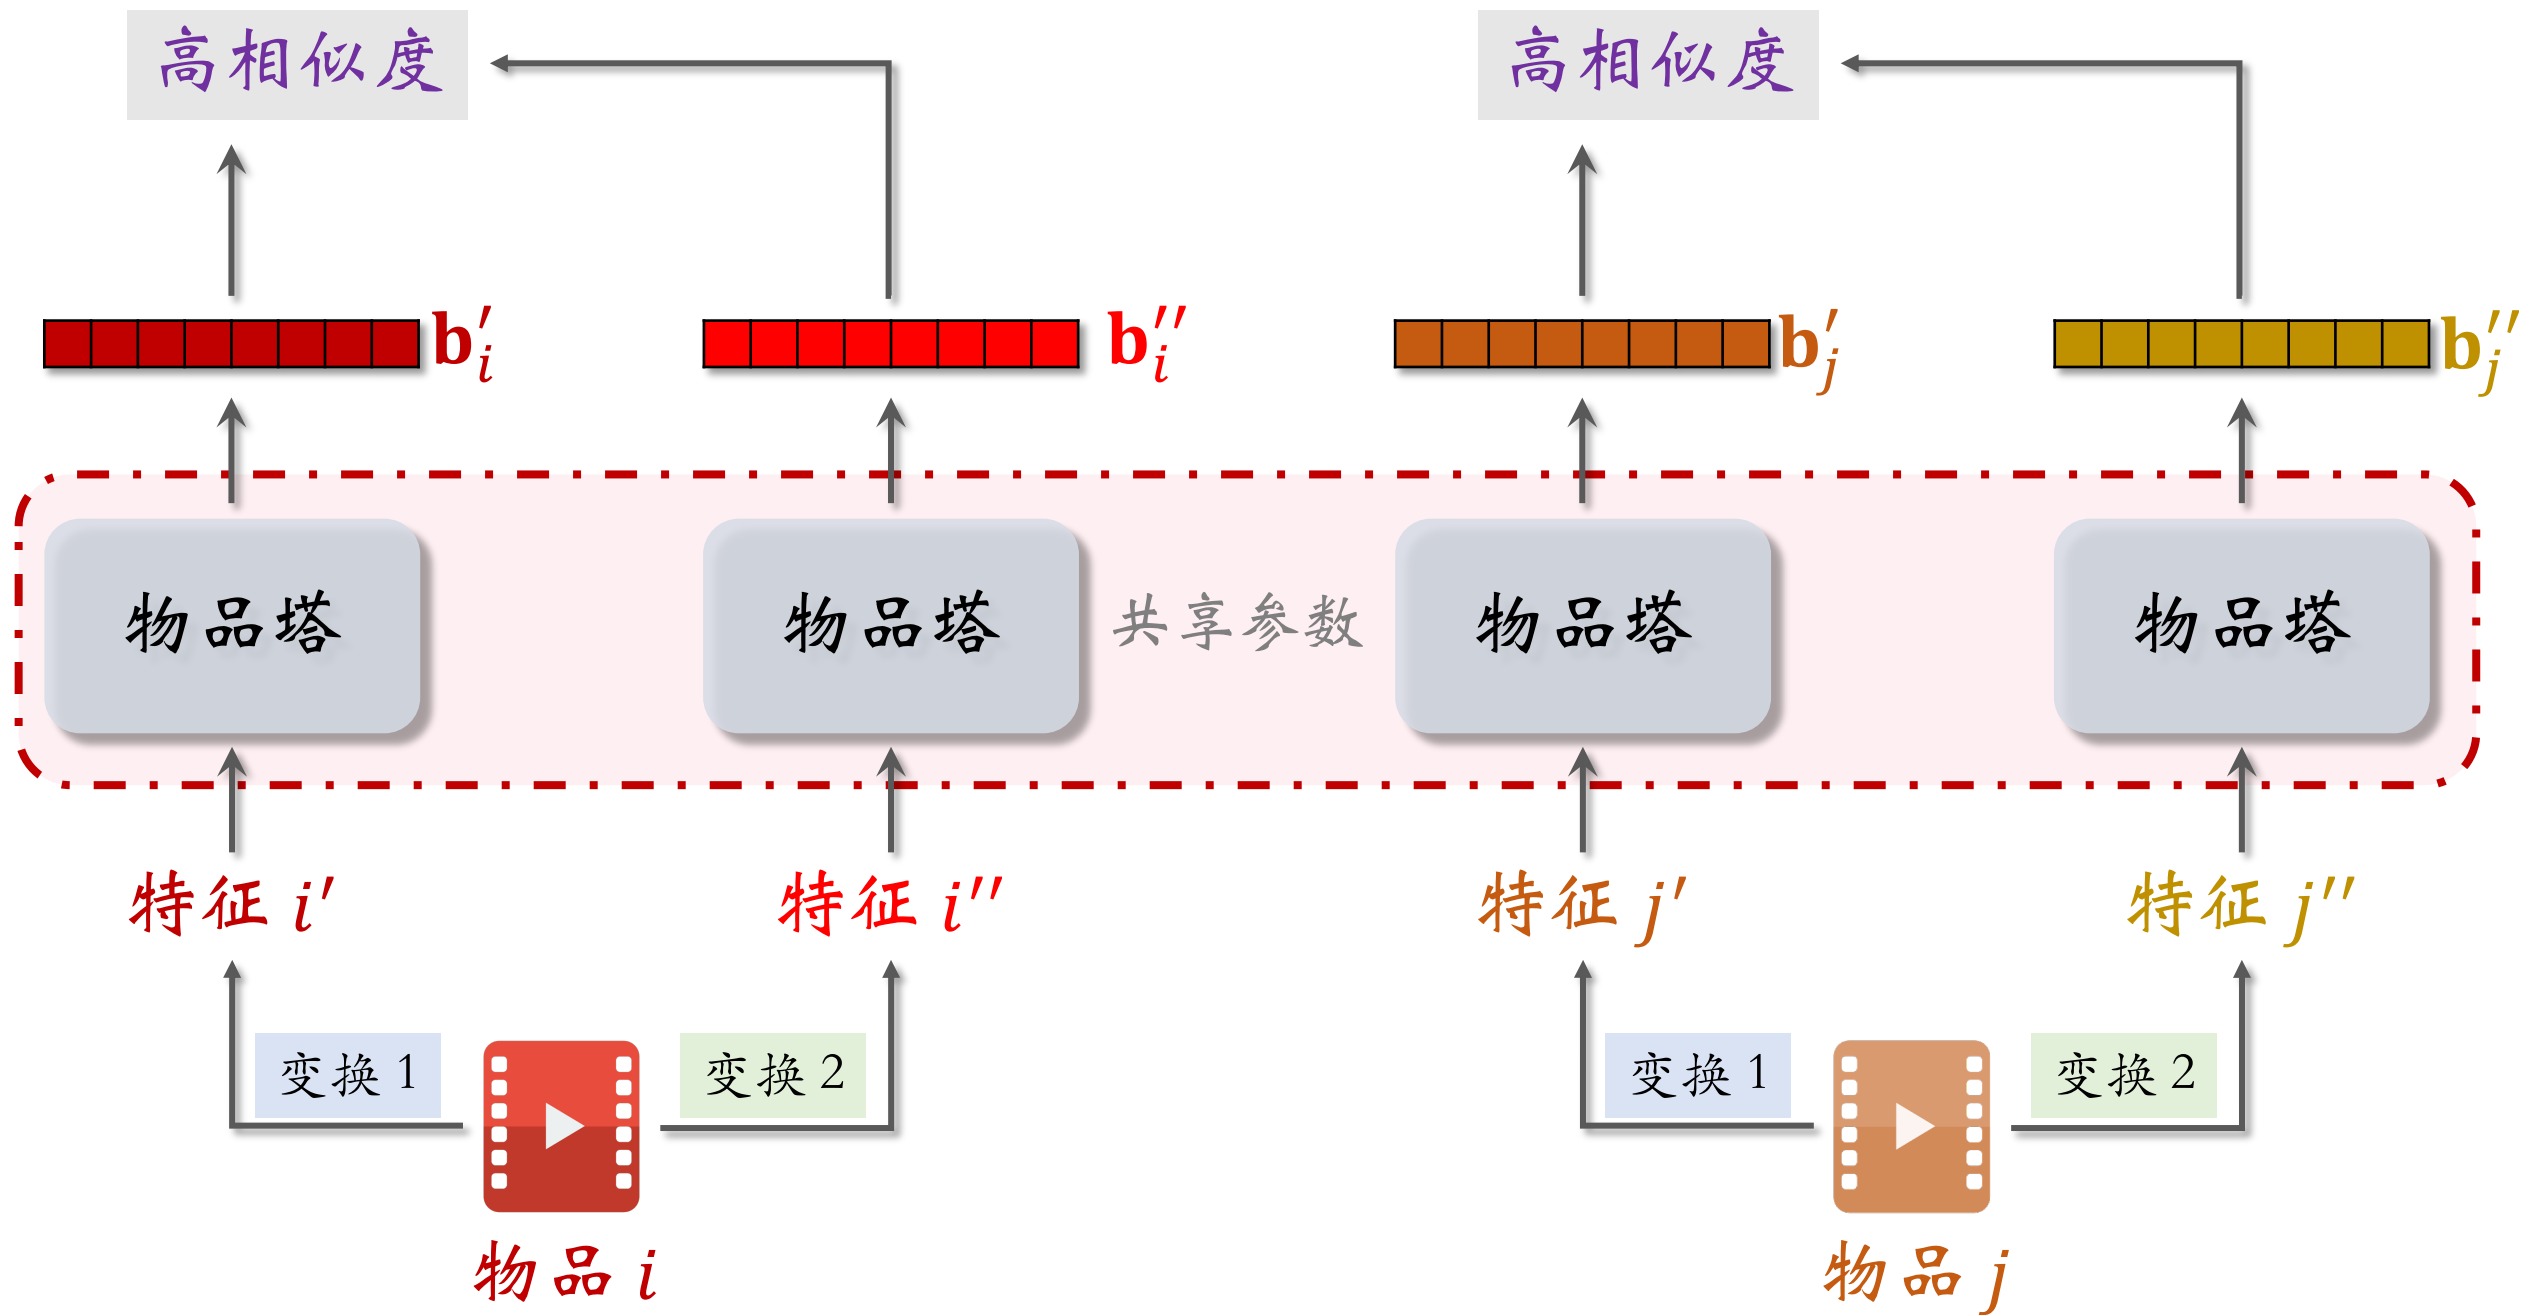
$$\frac{1}{n} \sum_{i=1}^n L_{\text{main}}[i].$$

# 自监督学习

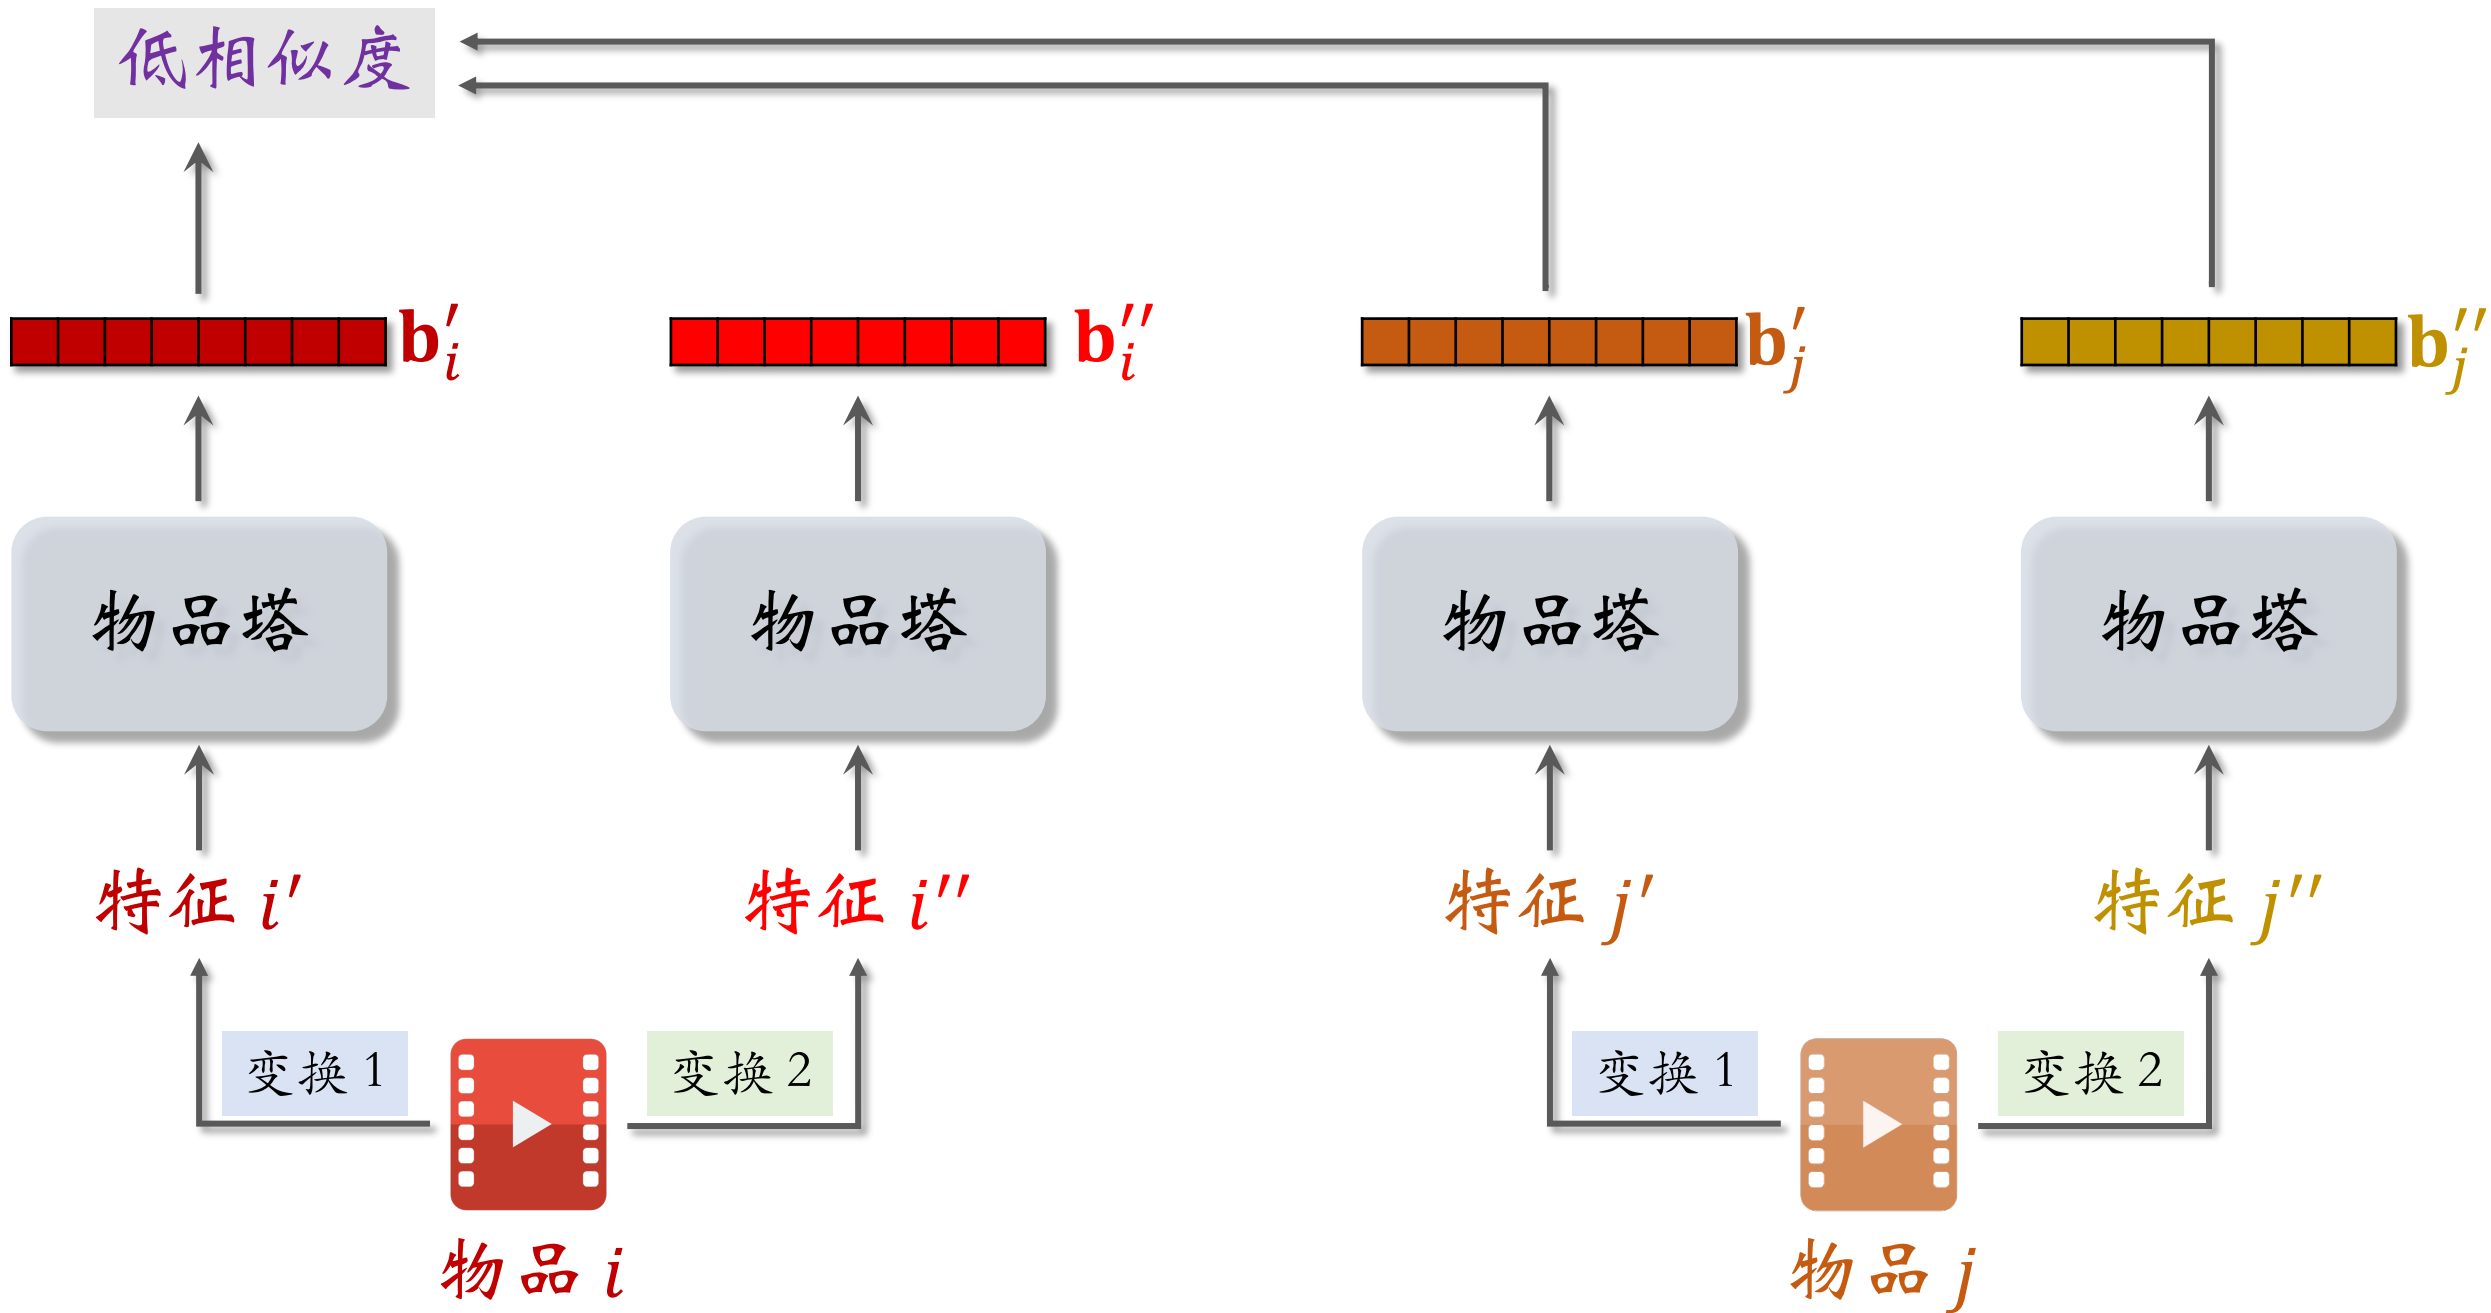
参考文献：

- Tiansheng Yao et al. [Self-supervised Learning for Large-scale Item Recommendations](#). In *CIKM*, 2021.









# 自监督学习

- 物品  $i$  的两个向量表征  $\mathbf{b}'_i$  和  $\mathbf{b}''_i$  有较高的相似度。
- 物品  $i$  和  $j$  的向量表征  $\mathbf{b}'_i$  和  $\mathbf{b}''_j$  有较低的相似度。
- 鼓励  $\cos(\mathbf{b}'_i, \mathbf{b}''_i)$  尽量大， $\cos(\mathbf{b}'_i, \mathbf{b}''_j)$  尽量小。

# 自监督学习

## 特征变换：Random Mask

- 随机选一些离散特征（比如类目），把它们遮住。
- 例：
  - 某物品的类目特征是  $\mathcal{U} = \{\text{数码}, \text{摄影}\}$ 。
  - Mask 后的类目特征是  $\mathcal{U}' = \{\text{default}\}$ 。

# 自监督学习

特征变换：Dropout（仅对多值离散特征生效）

- 一个物品可以有多个类目，那么类目是一个多值离散特征。
- Dropout：随机丢弃特征中 50% 的值。
- 例：
  - 某物品的类目特征是  $u = \{\text{美妆}, \text{摄影}\}$ 。
  - Dropout 后的类目特征是  $u' = \{\text{美妆}\}$ 。

# 自监督学习

## 特征变换：互补特征 (complementary)

- 假设物品一共有 4 种特征：

ID，类目，关键词，城市

- 随机分成两组：

{ID，关键词} 和 {类目，城市}

- { ID，default，关键词，default } → 物品表征
- { default，类目，default，城市 } → 物品表征

鼓励两个向量相似

# 自监督学习

特征变换：Mask 一组关联的特征

- 受众性别： $u = \{\text{男}, \text{女}, \text{中性}\}$
- 类目： $v = \{\text{美妆}, \text{数码}, \text{足球}, \text{摄影}, \text{科技}, \dots\}$
- $u = \text{女}$  和  $v = \text{美妆}$  同时出现的概率  $p(u, v)$  大。
- $u = \text{女}$  和  $v = \text{数码}$  同时出现的概率  $p(u, v)$  小。

# 自监督学习

特征变换：Mask 一组关联的特征

- $p(u)$ ：某特征取值为  $u$  的概率。
  - $p(\text{男性}) = 20\%$
  - $p(\text{女性}) = 30\%$
  - $p(\text{中性}) = 50\%$

# 自监督学习

特征变换：Mask 一组关联的特征

- $p(u)$  : 某特征取值为  $u$  的概率。
- $p(u, v)$  : 某特征取值为  $u$ ，另一个特征取值为  $v$ ，同时发生的概率。
  - $p(\text{女性}, \text{美妆}) = 3\%$
  - $p(\text{女性}, \text{数码}) = 0.1\%$



# 自监督学习

特征变换：Mask 一组关联的特征

- $p(u)$ ：某特征取值为  $u$  的概率。
- $p(u, v)$ ：某特征取值为  $u$ ，另一个特征取值为  $v$ ，同时发生的概率。
- 离线计算特征两两之间的关联，用互信息（mutual information）衡量：

$$\underline{MI(\mathcal{U}, \mathcal{V})} = \sum_{u \in \mathcal{U}} \sum_{v \in \mathcal{V}} p(u, v) \cdot \log \frac{p(u, v)}{p(u) \cdot p(v)}.$$

# 自监督学习

## 特征变换：Mask 一组关联的特征

- 设一共有  $k$  种特征。离线计算特征两两之间 MI，得到  $k \times k$  的矩阵。
- 随机选一个特征作为种子，找到种子最相关的  $k/2$  种特征。
- Mask 种子及其相关的  $k/2$  种特征，保留其余的  $k/2$  种特征。

# 自监督学习

## 特征变换：Mask 一组关联的特征

- 好处：比 random mask、dropout、互补特征等方法效果更好。
- 坏处：方法复杂，实现的难度大，不容易维护。

# 自监督学习

特征变换：Random Mask

特征变换：Dropout（仅对多值离散特征生效）

特征变换：互补特征（complementary）

特征变换：Mask 一组关联的特征

# 训练模型

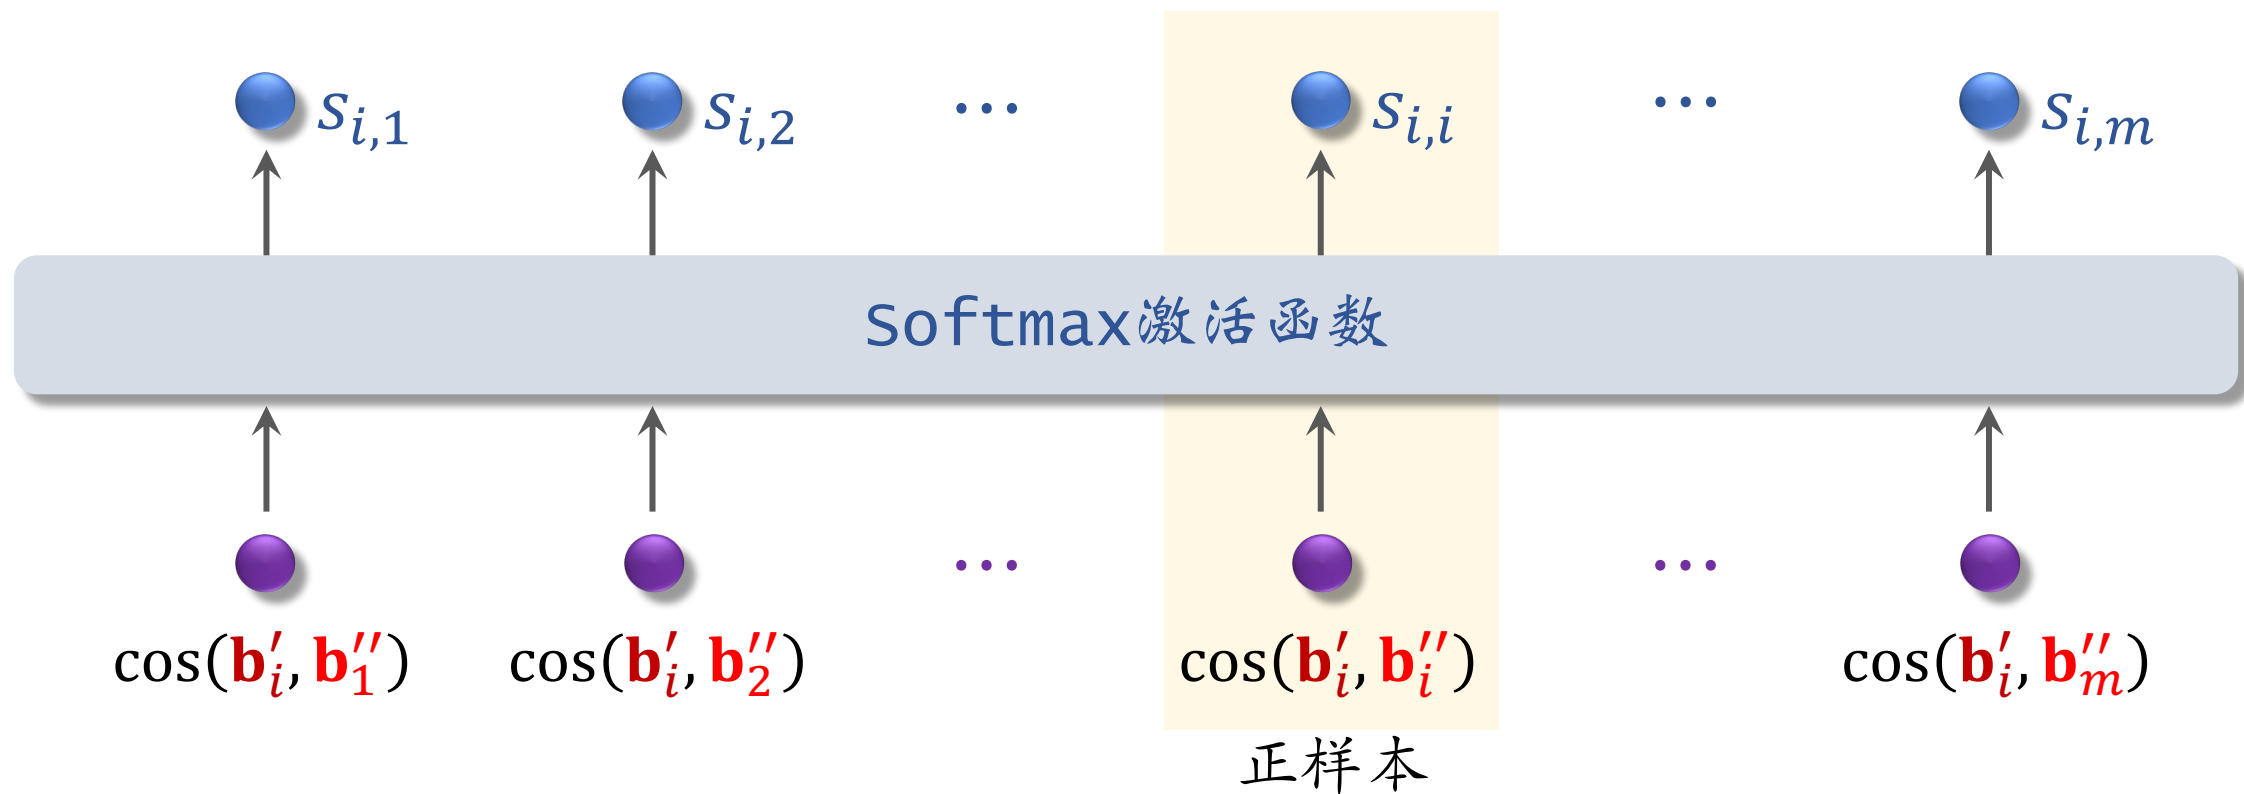
- 从全体物品中均匀抽样，得到  $m$  个物品，作为一个 batch。
- 做两类特征变换，物品塔输出两组向量：

$$\mathbf{b}'_1, \mathbf{b}'_2, \dots, \mathbf{b}'_m \quad \text{和} \quad \mathbf{b}''_1, \mathbf{b}''_2, \dots, \mathbf{b}''_m$$

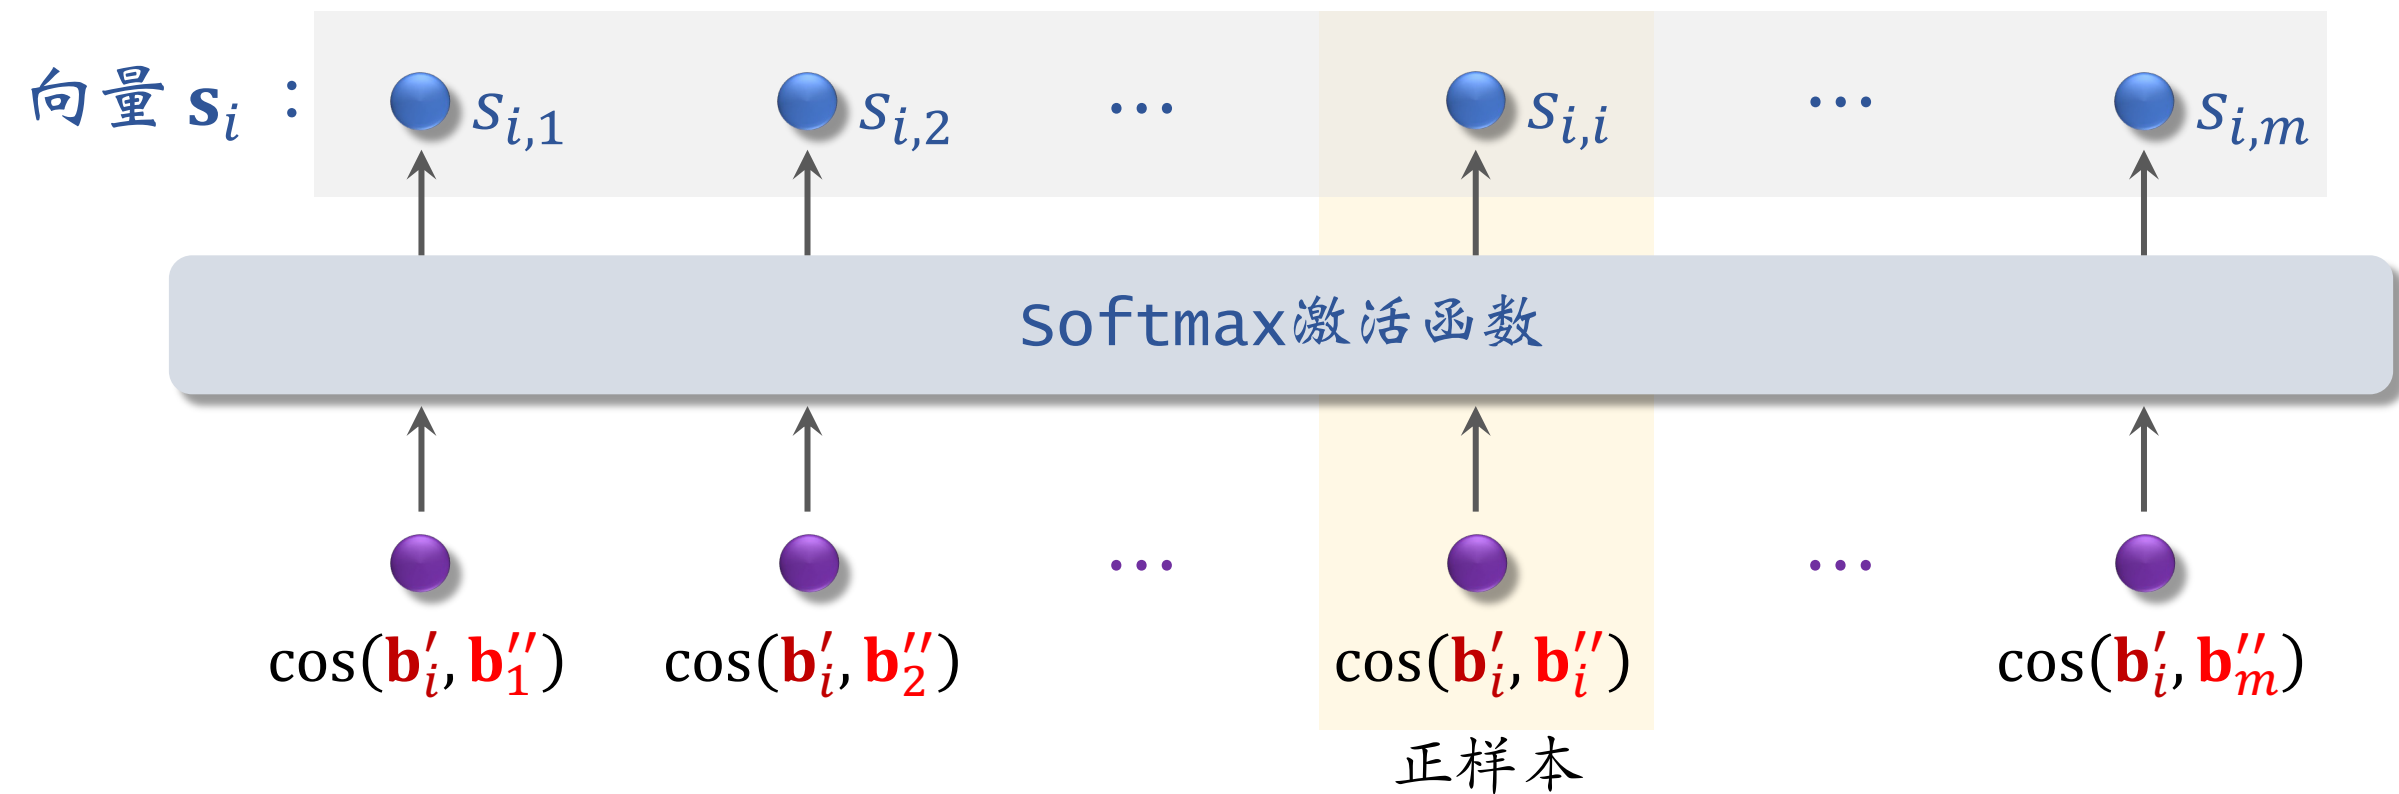
- 第  $i$  个物品的损失函数：

$$L_{\text{self}}[i] = -\log \left( \frac{\exp(\cos(\mathbf{b}'_i, \mathbf{b}''_i))}{\sum_{j=1}^m \exp(\cos(\mathbf{b}'_i, \mathbf{b}''_j))} \right).$$

# 训练模型




# 训练模型




# 训练模型

向量  $y_i$  :



向量  $s_i$  :



Softmax激活函数

$\cos(\mathbf{b}'_i, \mathbf{b}''_1)$

$\cos(\mathbf{b}'_i, \mathbf{b}''_2)$

...

$\cos(\mathbf{b}'_i, \mathbf{b}''_i)$

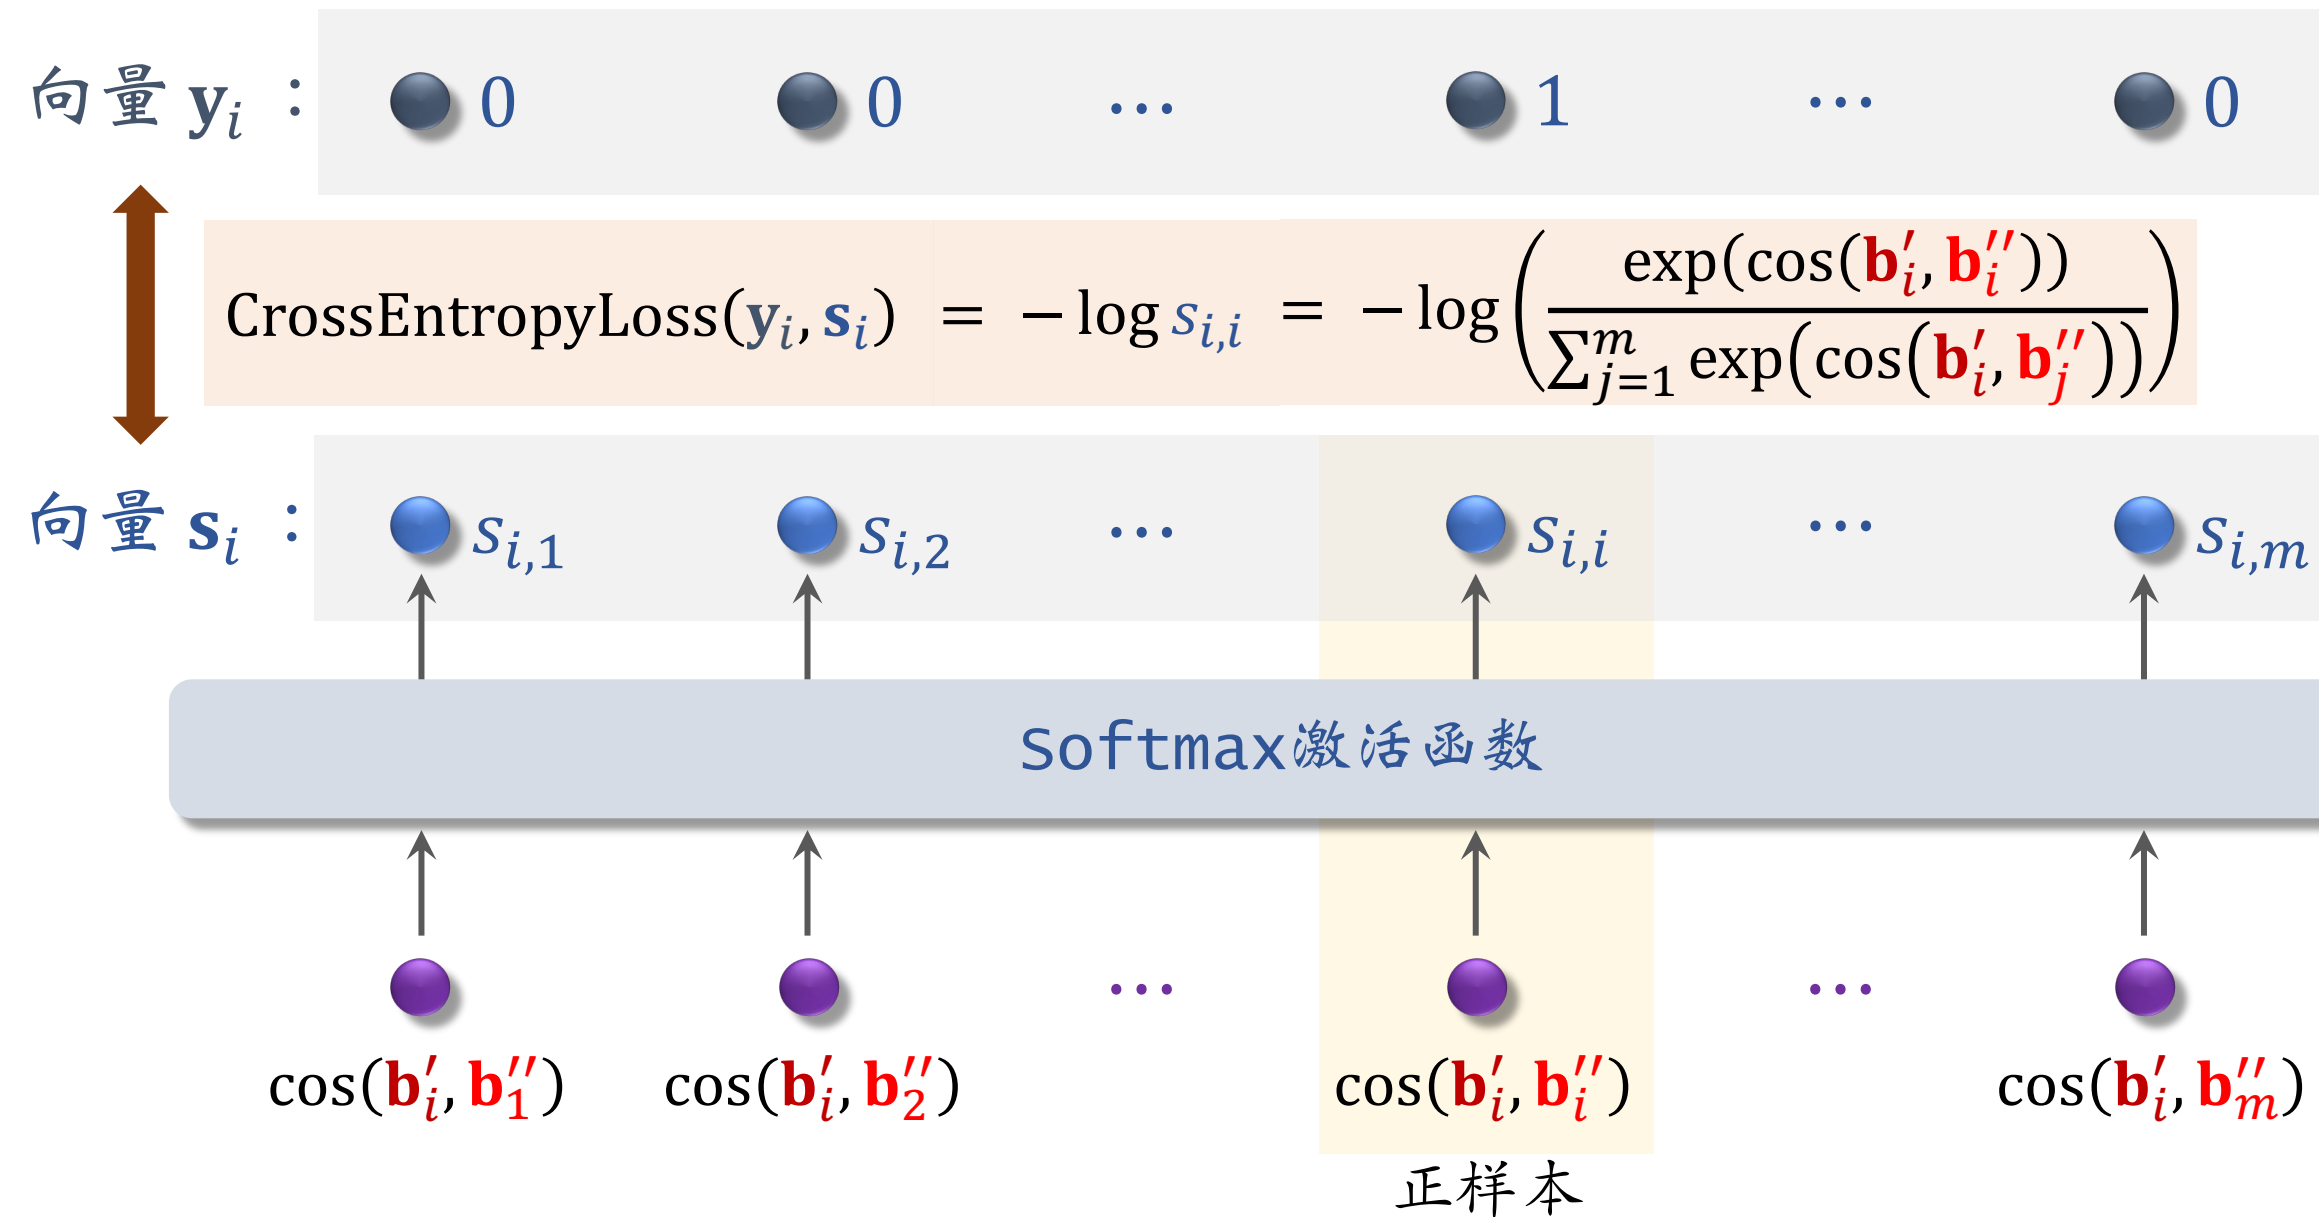
正样本

...

$\cos(\mathbf{b}'_i, \mathbf{b}''_m)$



# 训练模型



# 训练模型

- 自监督学习的损失函数：

$$\underline{L_{\text{self}}[i]} = -\log \left( \frac{\exp(\cos(\mathbf{b}'_i, \mathbf{b}''_i))}{\sum_{j=1}^m \exp(\cos(\mathbf{b}'_i, \mathbf{b}''_j))} \right).$$

- 做梯度下降，减小自监督学习的损失：

$$\underline{\frac{1}{m} \sum_{i=1}^m L_{\text{self}}[i]}.$$

# 总结

# 总结

- 双塔模型学不好低曝光物品的向量表征。
- 自监督学习：
  - 对物品做随机特征变换。
  - 特征向量  $\mathbf{b}'_i$  和  $\mathbf{b}''_i$  相似度高（相同物品）。
  - 特征向量  $\mathbf{b}'_i$  和  $\mathbf{b}''_j$  相似度低（不同物品）。
- 实验效果：低曝光物品、新物品的推荐变得更准。

# 训练模型

- 对点击做随机抽样，得到  $n$  对用户—物品二元组，作为一个 batch。
- 从全体物品中均匀抽样，得到  $m$  个物品，作为一个 batch。
- 做梯度下降，使得损失减小：

$$\frac{1}{n} \sum_{i=1}^n L_{\text{main}}[i] + \alpha \cdot \frac{1}{m} \sum_{j=1}^m L_{\text{self}}[j].$$

双塔模型的损失      自监督学习的损失

**Thank You!**

<http://wangshusen.github.io/>