

# Deep Retrieval

王树森

<http://wangshusen.github.io/>

# Deep Retrieval

- 经典的双塔模型把用户、物品表示为向量，线上做最近邻查找。
- Deep Retrieval [1] 把物品表征为路径（path），线上查找用户最匹配的路径。
- Deep Retrieval 类似于阿里的 TDM [2]。

## 参考文献：

1. Weihao Gao et al. [Learning A Retrievable Structure for Large-Scale Recommendations](#). In *CIKM*, 2021.
2. Han Zhu et al. [Learning Tree-based Deep Model for Recommender Systems](#). In *KDD*, 2018.

# Outline

## 1. 索引：

- 路径  $\rightarrow$  List<物品>
- 物品  $\rightarrow$  List<路径>

## 2. 预估模型：神经网络预估用户对路径的兴趣。


## 3. 线上召回：用户 $\rightarrow$ 路径 $\rightarrow$ 物品。

## 4. 训练：

- 学习神经网络参数。
- 学习物品表征（物品  $\rightarrow$  路径）。


# 索引

# 物品表征为路径



- 深度:  $\text{depth} = 3$ 。
- 宽度:  $\text{width} = K$ 。
- 把一个物品表示为一条路径 (path)，比如  $[2, 4, 1]$ 。

# 物品表征为路径



- 深度:  $\text{depth} = 3$ 。
- 宽度:  $\text{width} = K$ 。
- 把一个物品表示为一条路径 (path)，比如  $[2, 4, 1]$ 。
- 一个物品可以表示为多条路径，比如  $\{[2, 4, 1], [4, 1, 1]\}$ 。

# 物品到路径的索引

索引：  $\text{item} \rightarrow \text{List}\langle \text{path} \rangle$

- 一个物品对应多条路径。
- 用 3 个节点表示一条路径：  $\text{path} = [a, b, c]$ 。

索引：  $\text{path} \rightarrow \text{List}\langle \text{item} \rangle$

- 一条路径对应多个物品。

# 预估模型




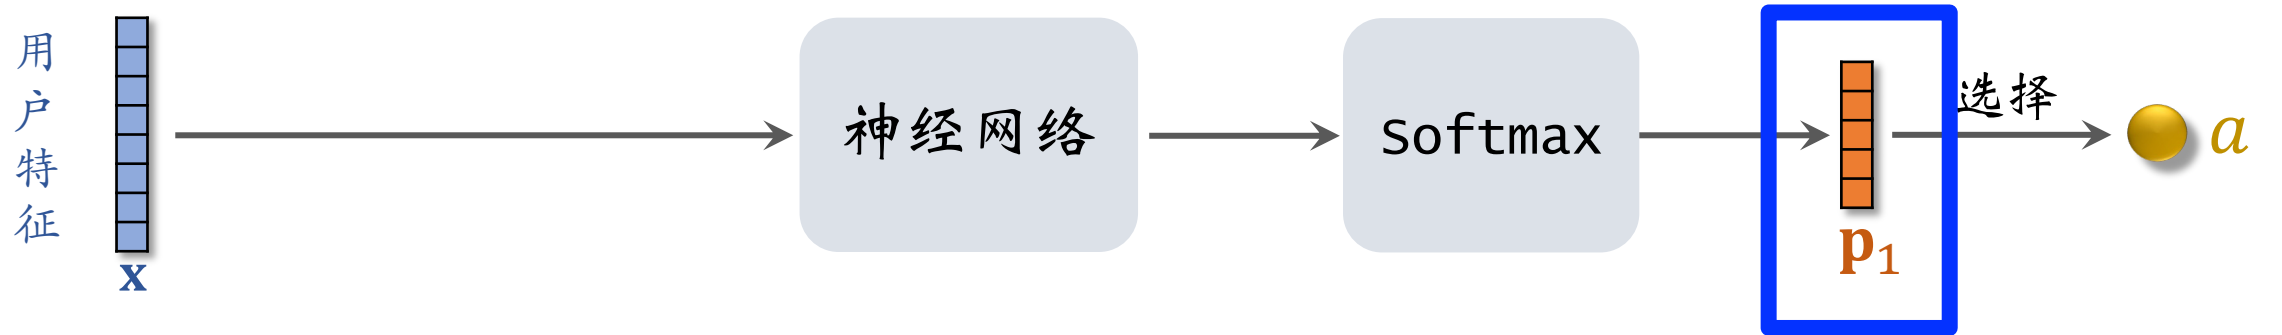
# 预估用户对路径的兴趣

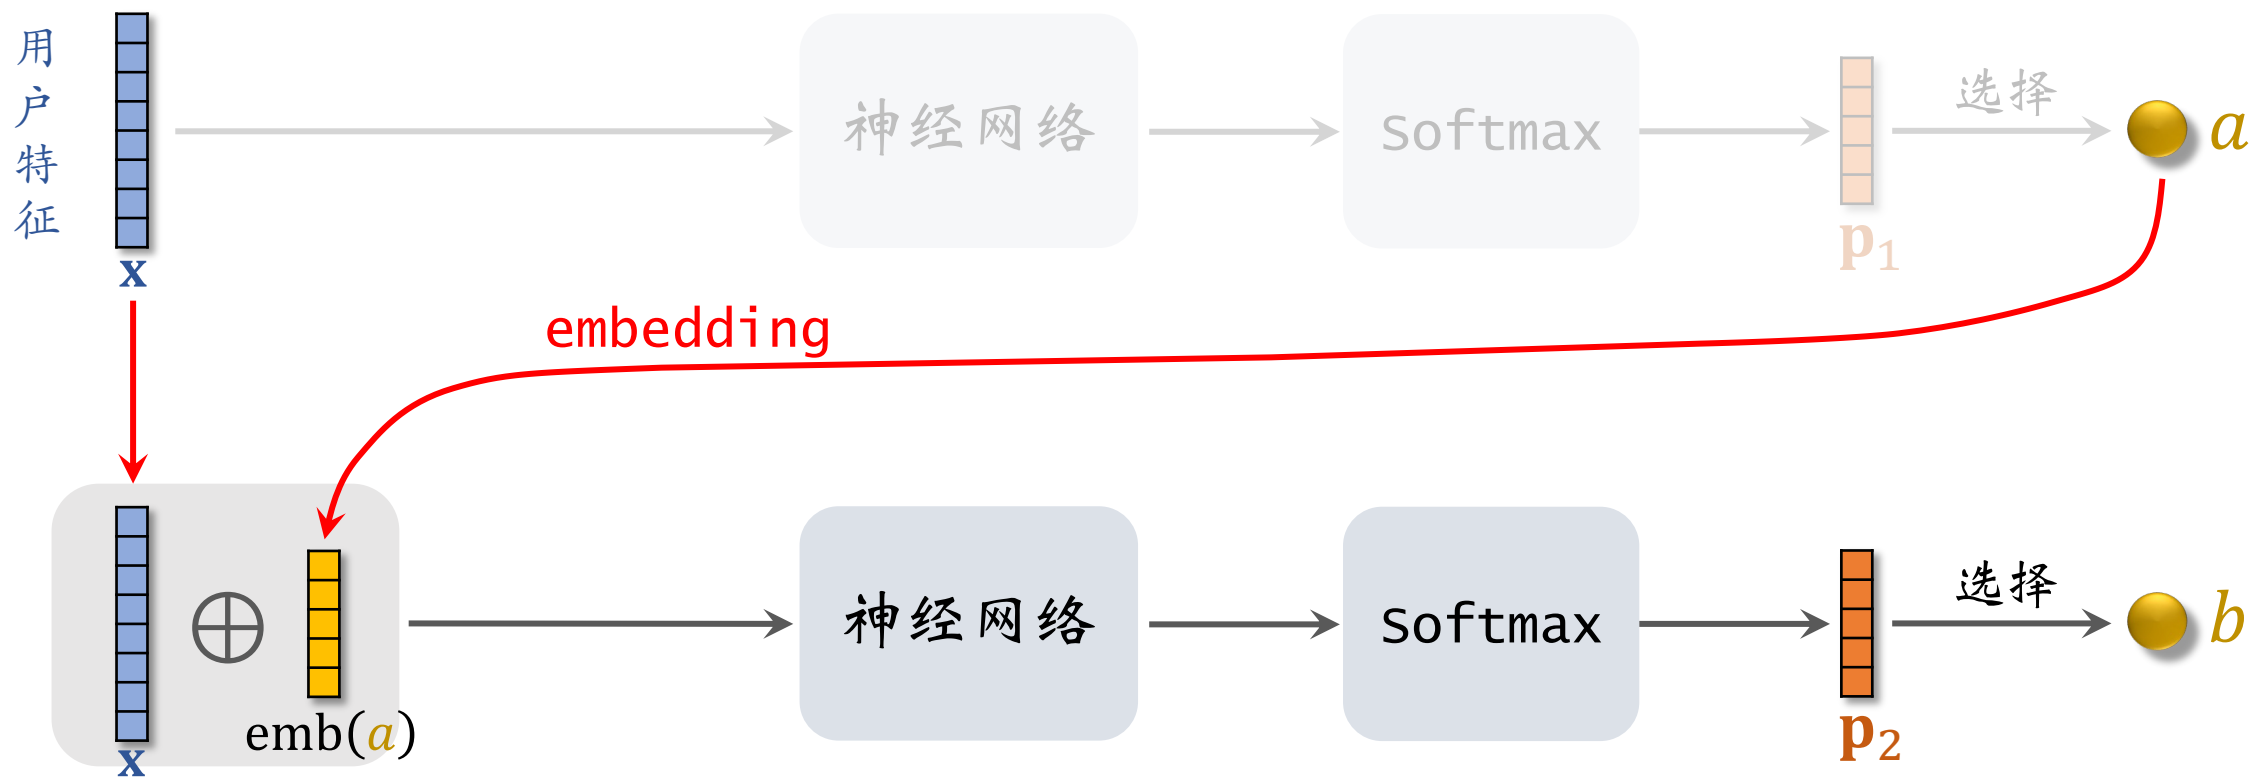
- 用 3 个节点表示一条路径： $\text{path} = [a, b, c]$ 。
- 给定用户特征  $\mathbf{x}$ ，预估用户对节点  $a$  的兴趣  $p_1(a|\mathbf{x})$ 。
- 给定  $\mathbf{x}$  和  $a$ ，预估用户对节点  $b$  的兴趣  $p_2(b|a;\mathbf{x})$ 。
- 给定  $\mathbf{x}, a, b$ ，预估用户对节点  $c$  的兴趣  $p_3(c|a, b;\mathbf{x})$ 。

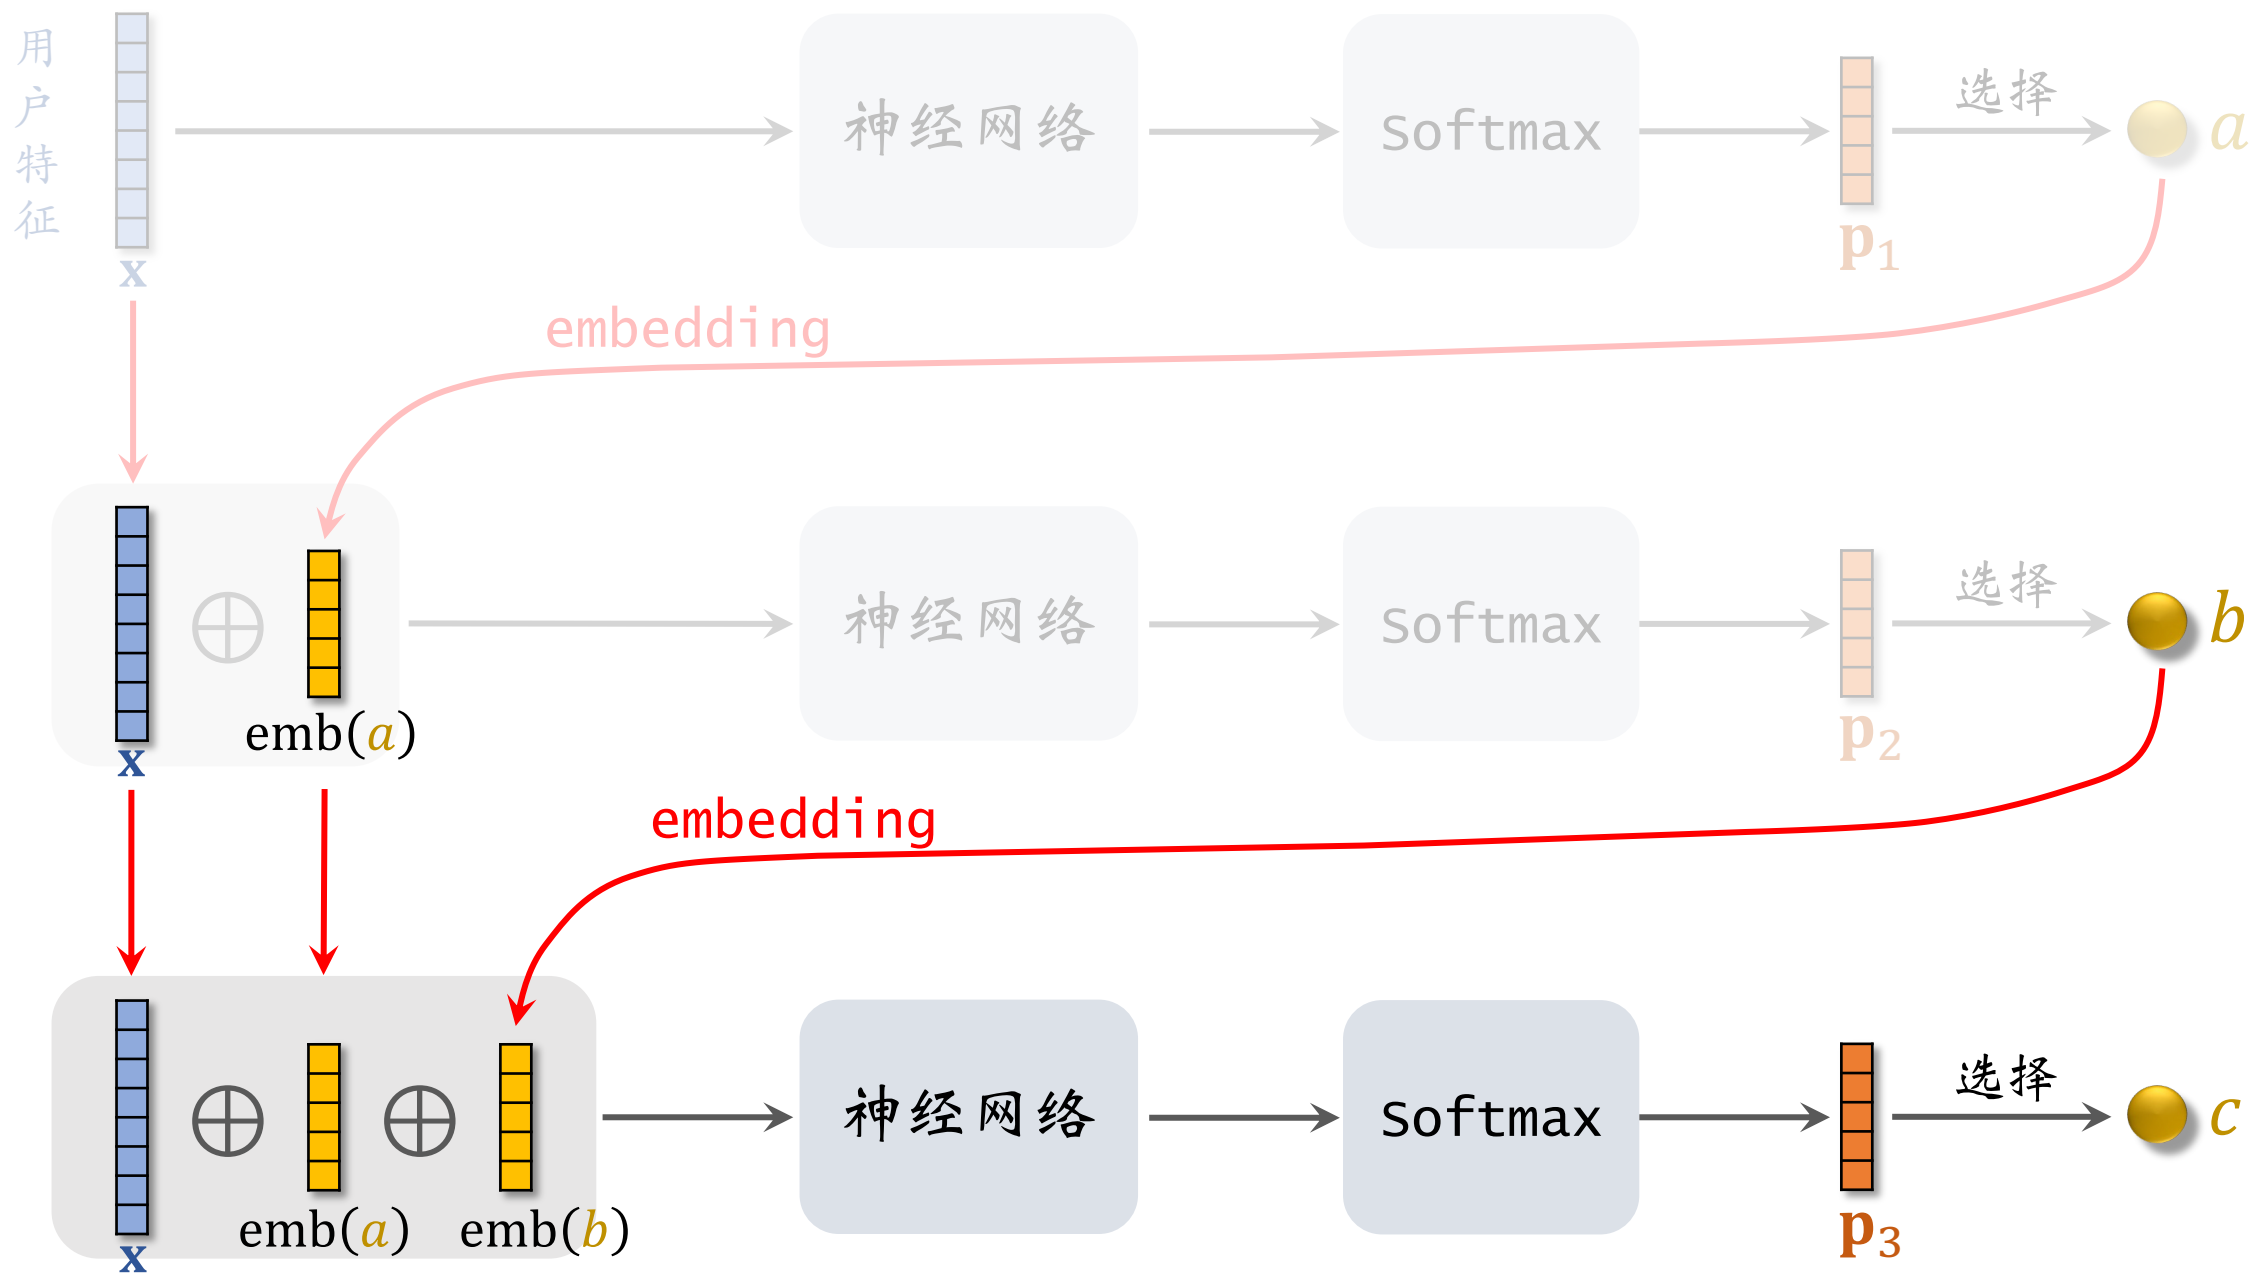
# 预估用户对路径的兴趣

- 用 3 个节点表示一条路径： $\text{path} = [a, b, c]$ 。
- 给定用户特征  $\mathbf{x}$ ，预估用户对节点  $a$  的兴趣  $p_1(a|\mathbf{x})$ 。
- 给定  $\mathbf{x}$  和  $a$ ，预估用户对节点  $b$  的兴趣  $p_2(b|a; \mathbf{x})$ 。
- 给定  $\mathbf{x}, a, b$ ，预估用户对节点  $c$  的兴趣  $p_3(c|a, b; \mathbf{x})$ 。
- 预估用户对  $\text{path} = [a, b, c]$  兴趣：

$$\underline{p(a, b, c|\mathbf{x})} = \underline{p_1(a|\mathbf{x}) \times p_2(b|a; \mathbf{x}) \times p_3(c|a, b; \mathbf{x})}.$$







线上召回

# 线上召回

召回：用户  $\rightarrow$  路径  $\rightarrow$  物品

- 第一步：给定用户特征，用 beam search 召回一批路径。
- 第二步：利用索引“path  $\rightarrow$  List<item>”，召回一批物品。
- 第三步：对物品做打分和排序，选出一个子集。

# Beam Search

- 假设有 3 层，每层  $K$  个节点，那么一共有  $K^3$  条路径。
- 用神经网络给所有  $K^3$  条路径打分，计算量太大。
- 用 beam search，可以减小计算量。
- 需要设置超参数 beam size。



# Beam Search (size = 1)

L1

1  $p_1(1 | \mathbf{x})$

2  $p_1(2 | \mathbf{x})$

3  $p_1(3 | \mathbf{x})$

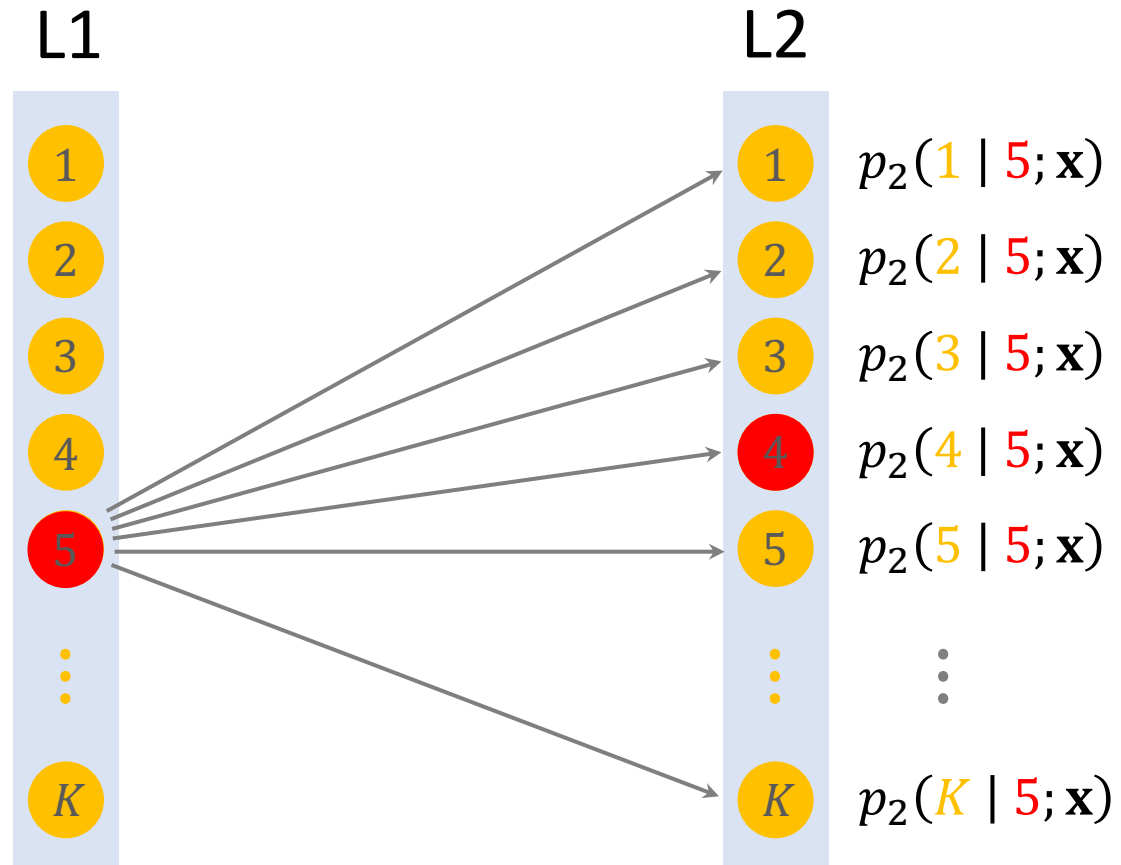
4  $p_1(4 | \mathbf{x})$

5  $p_1(5 | \mathbf{x})$


⋮

$K$   $p_1(K | \mathbf{x})$


# Beam Search (size = 1)




# Beam Search (size = 1)




# Beam Search (size = 1)



# Beam Search (size = 1)



# Beam Search (size = 1)



选中路径  $\text{path} = [5, 4, 1]$

# Beam Search

- 用户对  $\text{path} = [a, b, c]$  兴趣：

$$p(a, b, c | \mathbf{x}) = p_1(a | \mathbf{x}) \times p_2(b | a; \mathbf{x}) \times p_3(c | a, b; \mathbf{x}).$$

- 最优的路径：

$$[a^*, b^*, c^*] = \underset{a, b, c}{\operatorname{argmax}} p(a, b, c | \mathbf{x})$$

- 贪心算法 (beam size = 1) 选中的路径  $[a, b, c]$  未必是最优的路径。

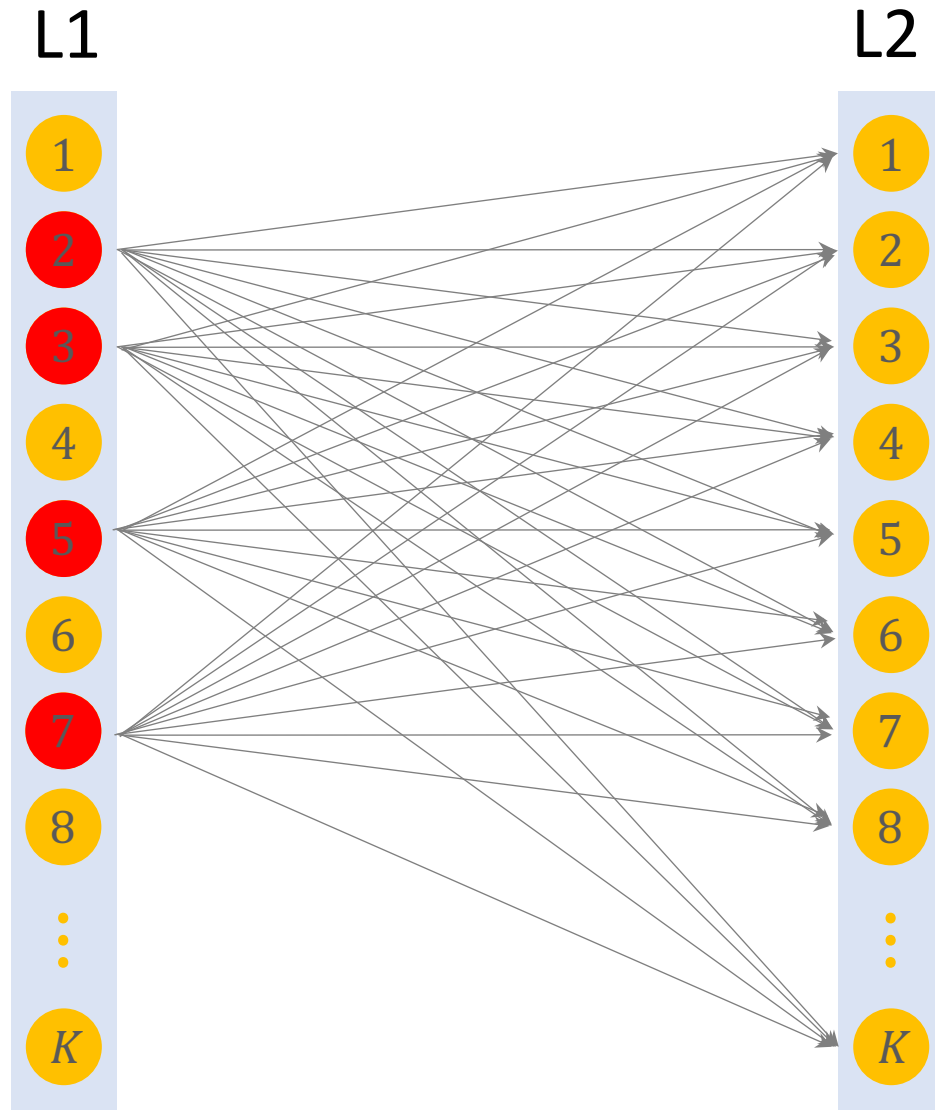
# Beam Search (size = 4)

L1


1	$p_1(1   \mathbf{x})$
2	$p_1(2   \mathbf{x})$
3	$p_1(3   \mathbf{x})$
4	$p_1(4   \mathbf{x})$
5	$p_1(5   \mathbf{x})$
6	$p_1(6   \mathbf{x})$
7	$p_1(7   \mathbf{x})$
8	$p_1(8   \mathbf{x})$
⋮	⋮
$K$	$p_1(K   \mathbf{x})$



# Beam Search (size = 4)



# Beam Search (size = 4)

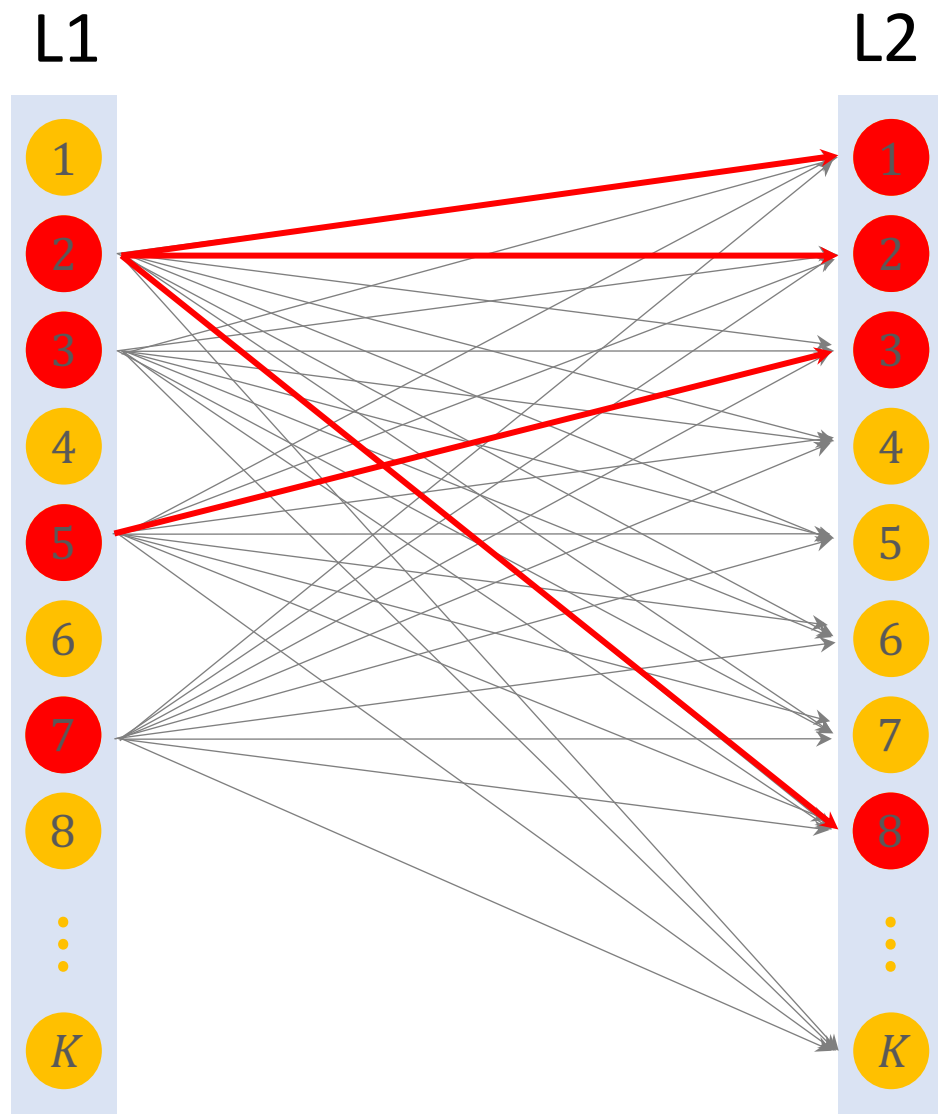


- 对于每个被选中的节点  $a$ ，计算用户对路径  $[a, b]$  的兴趣：

$$\underline{p_1(a|\mathbf{x}) \times p_2(b|a; \mathbf{x})}.$$

- 算出  $4 \times K$  个分数，每个分数对应一条路径，选出分数 top 4 路径。

# Beam Search (size = 4)

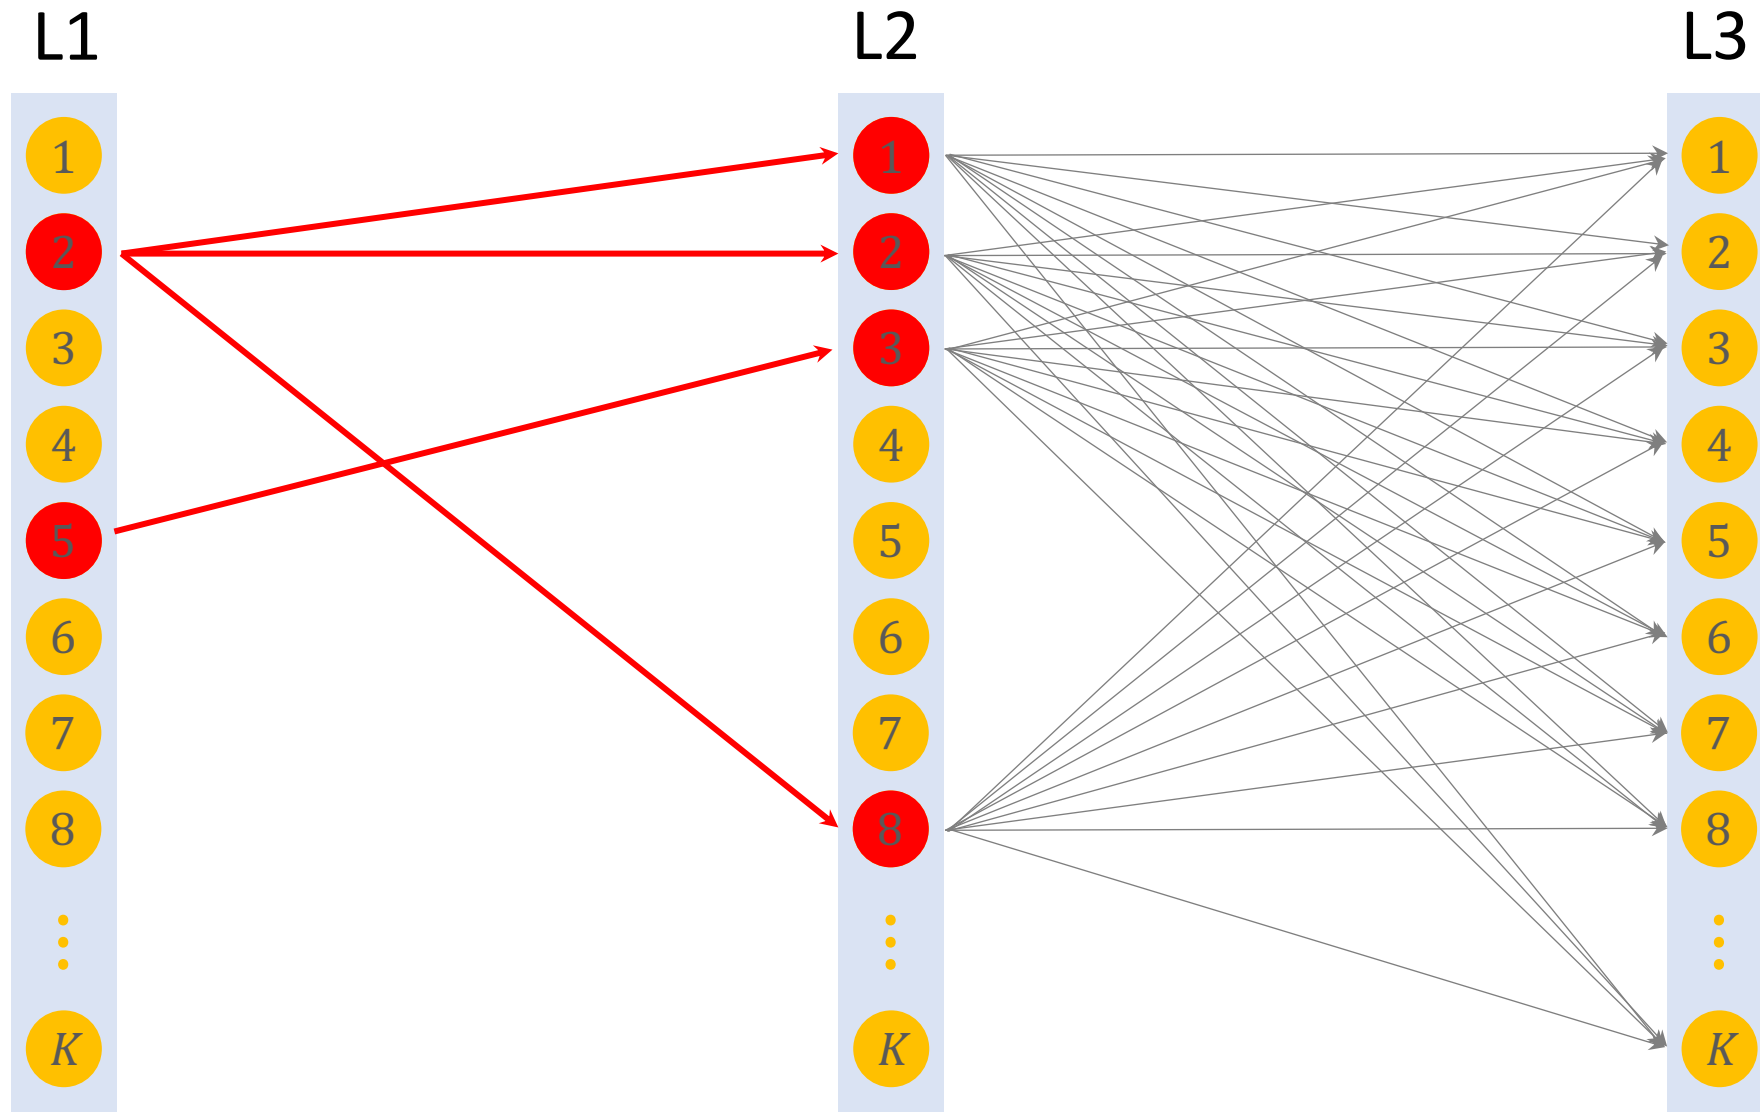


- 对于每个被选中的节点  $a$ ，  
计算用户对路径  $[a, b]$  的兴趣：


$$p_1(a|\mathbf{x}) \times p_2(b|a; \mathbf{x}).$$

- 算出  $4 \times K$  个分数，每个分数对应一条路径，选出分数 top 4 路径。


# Beam Search (size = 4)



# Beam Search (size = 4)



# Beam Search (size = 4)



# 线上召回

- 第一步：给定用户特征，用神经网络做预估，用 beam search 召回一批路径。
- 第二步：利用索引，召回一批物品。
  - 查看索引 path  $\rightarrow$  List<item>。
  - 每条路径对应多个物品。
- 第三步：对物品做排序，选出一个子集。

线上召回：user  $\rightarrow$  path  $\rightarrow$  item

训练



# 训练

## 同时学习神经网络参数和物品表征

- 神经网络  $p(a, b, c \mid \mathbf{x})$  预估用户对路径  $[a, b, c]$  的兴趣。
- 把一个物品表征为多条路径  $\{[a, b, c]\}$ ，建立索引：
  - $\text{item} \rightarrow \text{List}\langle \text{path} \rangle$ ，
  - $\text{path} \rightarrow \text{List}\langle \text{item} \rangle$ 。
- 正样本  $(\text{user}, \text{item})$ ：  $\text{click}(\text{user}, \text{item}) = 1$ 。

# 学习神经网络参数

- 物品表征为  $J$  条路径： $[a_1, b_1, c_1], \dots, [a_J, b_J, c_J]$ 。

- 用户对路径  $[a, b, c]$  的兴趣：

$$p(a, b, c \mid \mathbf{x}) = p_1(a \mid \mathbf{x}) \times p_2(b \mid a; \mathbf{x}) \times p_3(c \mid a, b; \mathbf{x}).$$

- 如果用户点击过物品，说明用户对  $J$  条路径感兴趣。

# 学习神经网络参数

- 物品表征为  $J$  条路径： $[a_1, b_1, c_1], \dots, [a_J, b_J, c_J]$ 。

- 用户对路径  $[a, b, c]$  的兴趣：

$$p(a, b, c \mid \mathbf{x}) = p_1(a \mid \mathbf{x}) \times p_2(b \mid a; \mathbf{x}) \times p_3(c \mid a, b; \mathbf{x}).$$

- 如果用户点击过物品，说明用户对  $J$  条路径感兴趣。

- 应该让  $\sum_{j=1}^J p(a_j, b_j, c_j \mid \mathbf{x})$  变大。

- 损失函数： $\text{loss} = -\log\left(\sum_{j=1}^J p(a_j, b_j, c_j \mid \mathbf{x})\right)$ 。

# 学习物品表征

- 用户 user 对路径  $\text{path} = [a, b, c]$  的兴趣记作：

$$\underline{p(\text{path} \mid \text{user})} = \underline{p(a, b, c \mid \mathbf{x})}.$$

- 物品 item 与路径 path 的相关性：

$$\underline{\text{score}(\text{item}, \text{path})} = \sum_{\text{user}} \underline{p(\text{path} \mid \text{user})} \times \text{click}(\text{user}, \text{item}).$$

用户对路径的兴趣

是否点击 (0或1)

# 学习物品表征

- 用户 user 对路径  $\text{path} = [a, b, c]$  的兴趣记作：

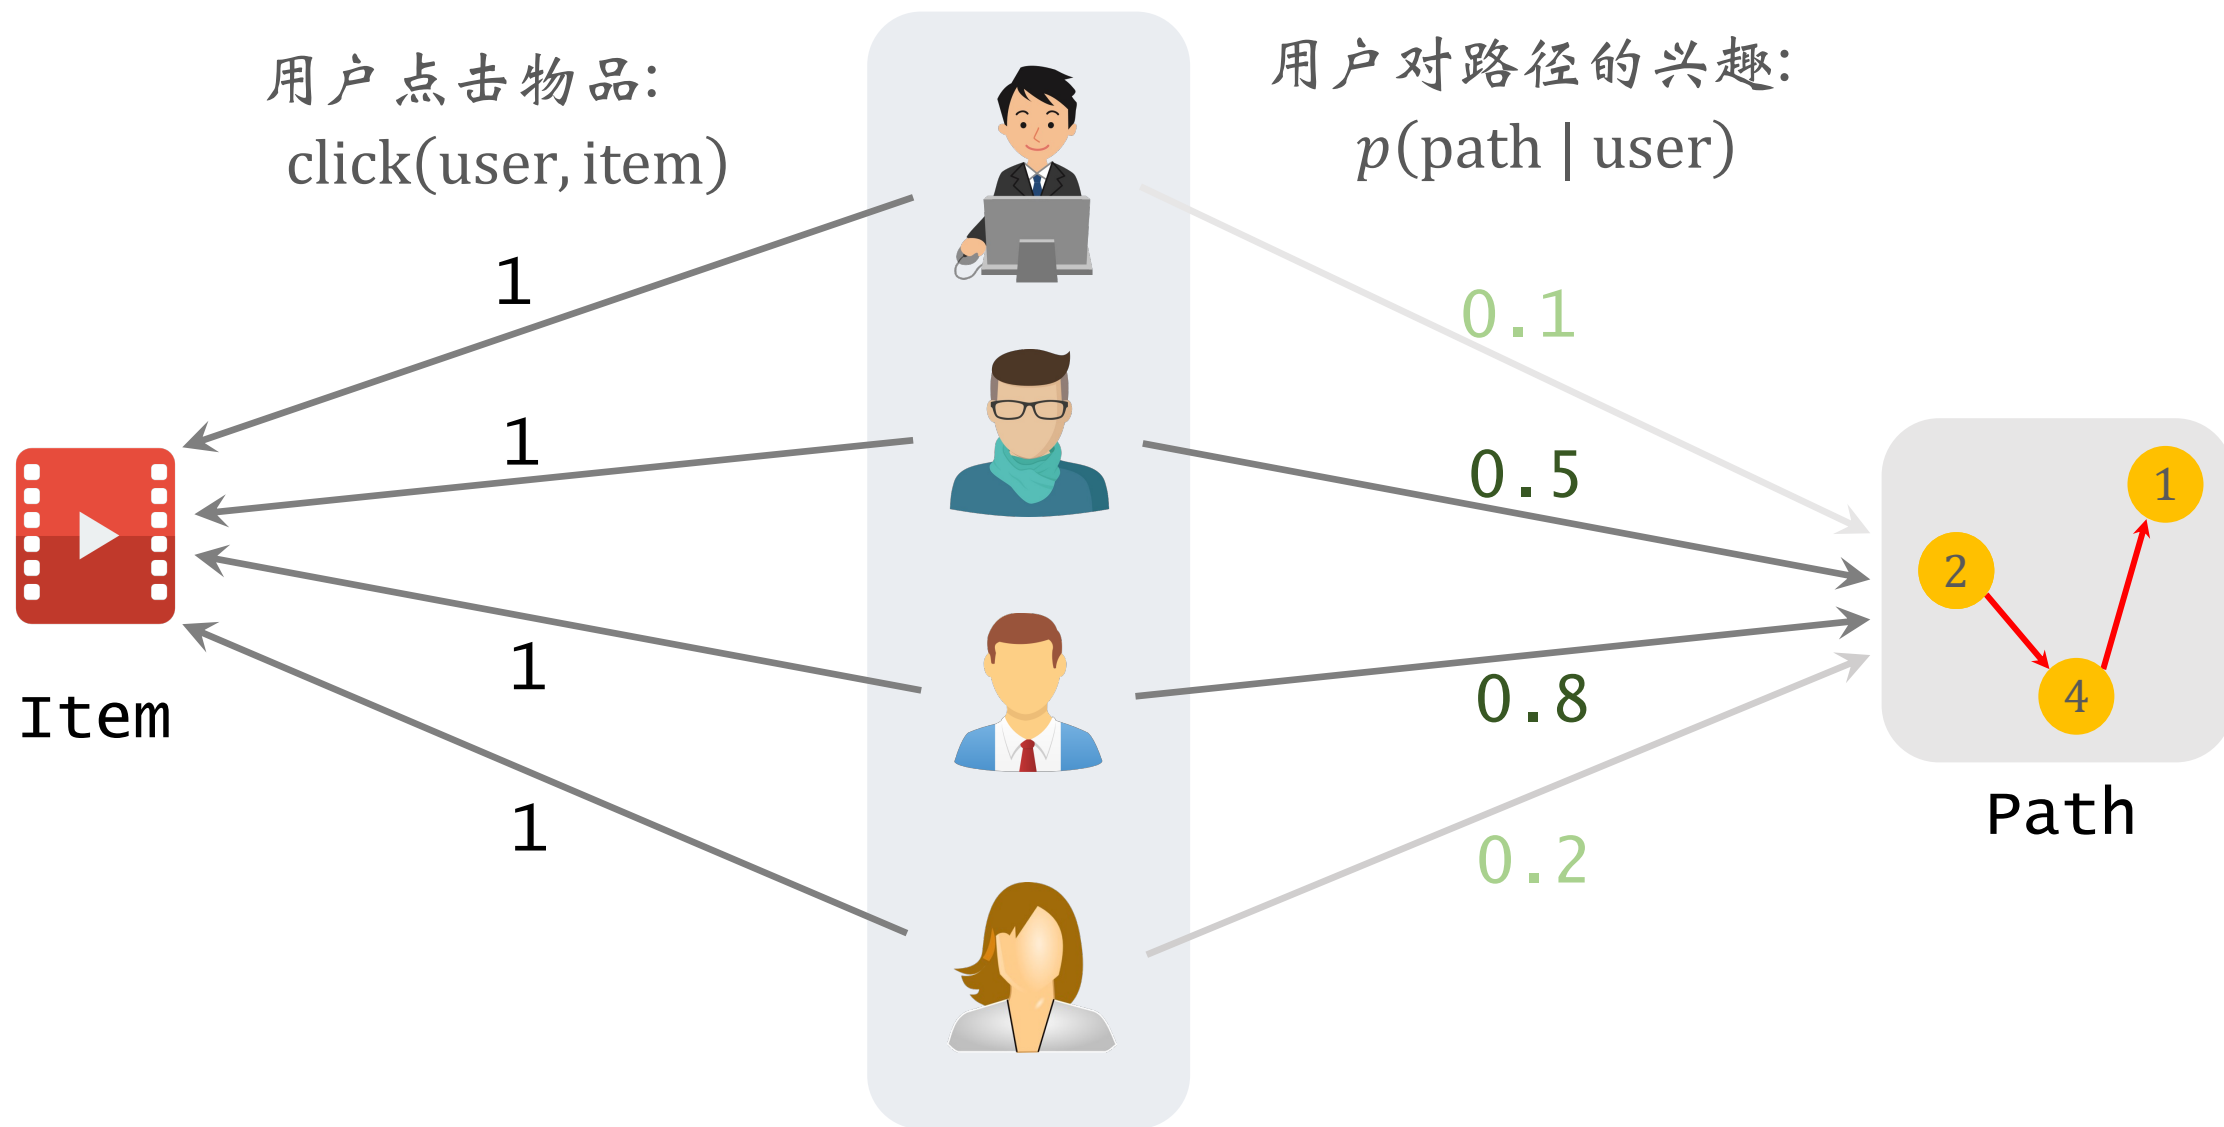
$$p(\text{path} \mid \text{user}) = p(a, b, c \mid \mathbf{x}).$$

- 物品 item 与路径 path 的相关性：

$$\underline{\text{score}(\text{item}, \text{path})} = \sum_{\text{user}} \underline{p(\text{path} \mid \text{user})} \times \text{click}(\text{user}, \text{item}).$$

- 根据  $\text{score}(\text{item}, \text{path})$  选出  $J$  条路径作为 item 的表征。

# 表征：物品 $\rightarrow$ 路径



# 学习物品表征

- 选出  $J$  条路径  $\Pi = \{\text{path}_1, \dots, \text{path}_J\}$ ，作为物品的表征。
- 损失函数（选择与 item 高度相关的 path）：

$$\text{loss}(\text{item}, \Pi) = - \log\left(\sum_{j=1}^J \text{score}(\text{item}, \text{path}_j)\right).$$

- 正则项（避免过多的 item 集中在一条 path 上）：

$$\text{reg}(\text{path}_j) = (\text{number of items on path}_j)^4.$$

# 学习物品表征

## 用贪心算法更新路径

- 假设已经把物品表征为  $J$  条路径  $\Pi = \{\text{path}_1, \dots, \text{path}_J\}$ 。
- 每次固定  $\{\text{path}_i\}_{i \neq l}$ ，并从未被选中的路径中，选出一条作为新的  $\text{path}_l$ ：

$$\text{path}_l \leftarrow \operatorname{argmin}_{\text{path}_l} \text{loss}(\text{item}, \Pi) + \alpha \cdot \text{reg}(\text{path}_l).$$

- 选中的路径有较高的分数  $\text{score}(\text{item}, \text{path}_l)$ ，而且路径上的物品数量不会太多。



# 训练

## 更新神经网络

- 神经网络判断用户对路径的兴趣：

$$p(\text{path} \mid \mathbf{x}).$$

- 训练所需的数据：（1）“物品 → 路径”的索引，（2）用户点击过的物品。
- 如果用户点击过物品，且物品对应路径  $\text{path}$ ，则更新神经网络参数使  $p(\text{path} \mid \mathbf{x})$  变大。

## 更新物品的表征

# 训练

## 更新神经网络

- 神经网络判断用户对路径的兴趣：

$$p(\text{path} \mid \mathbf{x}).$$

- 训练所需的数据：（1）“物品 → 路径”的索引，（2）用户点击过的物品。
- 如果用户点击过物品，且物品对应路径  $\text{path}$ ，则更新神经网络参数使  $p(\text{path} \mid \mathbf{x})$  变大。

## 更新物品的表征

- 判断物品与路径的相关性：

物品  $\leftarrow$  用户  $\rightarrow$  路径

用户点击过物品

神经网络的打分

- 让每个物品关联  $J$  条路径。
  - 物品和路径要有很高的相关性。
  - 一条路径上不能有过多的物品。

# 总结

# Deep Retrieval

召回：用户  $\rightarrow$  路径  $\rightarrow$  物品

- 给定用户特征  $\mathbf{x}$ ，用神经网络预估用户对路径  $\text{path} = [a, b, c]$  的兴趣，分数记作  $p(\text{path} \mid \mathbf{x})$ .
- 用 beam search 寻找分数  $p(\text{path} \mid \mathbf{x})$  最高的  $s$  条  $\text{path}$ 。

# Deep Retrieval

召回： 用户  $\rightarrow$  路径  $\rightarrow$  物品

- 给定用户特征  $\mathbf{x}$ ，用神经网络预估用户对路径  $\text{path} = [a, b, c]$  的兴趣，分数记作  $p(\text{path} | \mathbf{x})$ 。
- 用 beam search 寻找分数  $p(\text{path} | \mathbf{x})$  最高的  $s$  条 path。
- 利用索引 “ $\text{path} \rightarrow \text{List}\langle \text{item} \rangle$ ” 召回每条路径上的  $n$  个物品。
- 一共召回  $s \times n$  个物品，对物品做初步排序，返回分数最高的若干物品。

# Deep Retrieval

训练：同时学习 **用户—路径** 和 物品—路径 的关系

- 一个物品被表征为  $J$  条路径： $\text{path}_1, \dots, \text{path}_J$ 。
- 如果用户点击过物品，则更新神经网络参数，使分数增大：

$$\sum_{j=1}^J p(\text{path}_j \mid \mathbf{x}) .$$

# Deep Retrieval

训练：同时学习 用户—路径 和 物品—路径 的关系

- 一个物品被表征为  $J$  条路径：  $\text{path}_1, \dots, \text{path}_J$ 。
- 如果用户点击过物品，则更新神经网络参数，使分数增大：

$$\sum_{j=1}^J p(\text{path}_j | \mathbf{x}) .$$

- 如果用户对路径的兴趣分数  $p(\text{path} | \mathbf{x})$  较高，且用户点击过物品  $\text{item}$ ，则  $\text{item}$  与  $\text{path}$  具有相关性。
- 寻找与  $\text{item}$  最相关的  $J$  条  $\text{path}$ ，且避免一条路径上物品过多。

**Thank You!**

<http://wangshusen.github.io/>