

推荐系统中的多样性

王树森

<http://wangshusen.github.io/>



物品相似性的度量


相似性的度量

- 基于物品属性标签。
 - 类目、品牌、关键词……
- 基于物品向量表征。
 - 用召回的双塔模型学到的物品向量（不好）。
 - 基于内容的向量表征（好）。


基于物品属性标签

- 物品属性标签：类目、品牌、关键词……
- 根据 一级类目、二级类目、品牌 计算相似度。
 - 物品 i ：美妆、彩妆、香奈儿。
 - 物品 j ：美妆、香水、香奈儿。
 - 相似度： $\text{sim}_1(i, j) = 1$ ， $\text{sim}_2(i, j) = 0$ ， $\text{sim}_3(i, j) = 1$ 。


双塔模型的物品向量表征



基于图文内容的物品表征



在日本买柴犬最详细解说
我是店长八谷。我是日本人，今年是我在东京开宠物店的第16年。
很多中国客人特意来日本买柴犬。有客人说大阪某宠物店60万日元（约4w人民币）一条柴犬。
日本柴犬真那么贵嘛？怎么可能💣💣💣
这是八谷为过往客人办理柴犬的费用💰
中国的朋友只看这一篇就可以了解大致的行情📊



基于图文内容的物品向量表征

- CLIP [1] 是当前公认最有效的预训练方法。
- 思想：对于图片—文本二元组，预测图文是否匹配。
- 优势：无需人工标注。小红书的笔记天然包含图片+文字，大部分笔记图文相关。

参考文献：

1. Radford et al. [Learning transferable visual models from natural language supervision](#). In *ICML*, 2021.

基于图文内容的物品表征

图片:



文字:



⋮

⋮



基于图文内容的物品表征

图片:

文字:



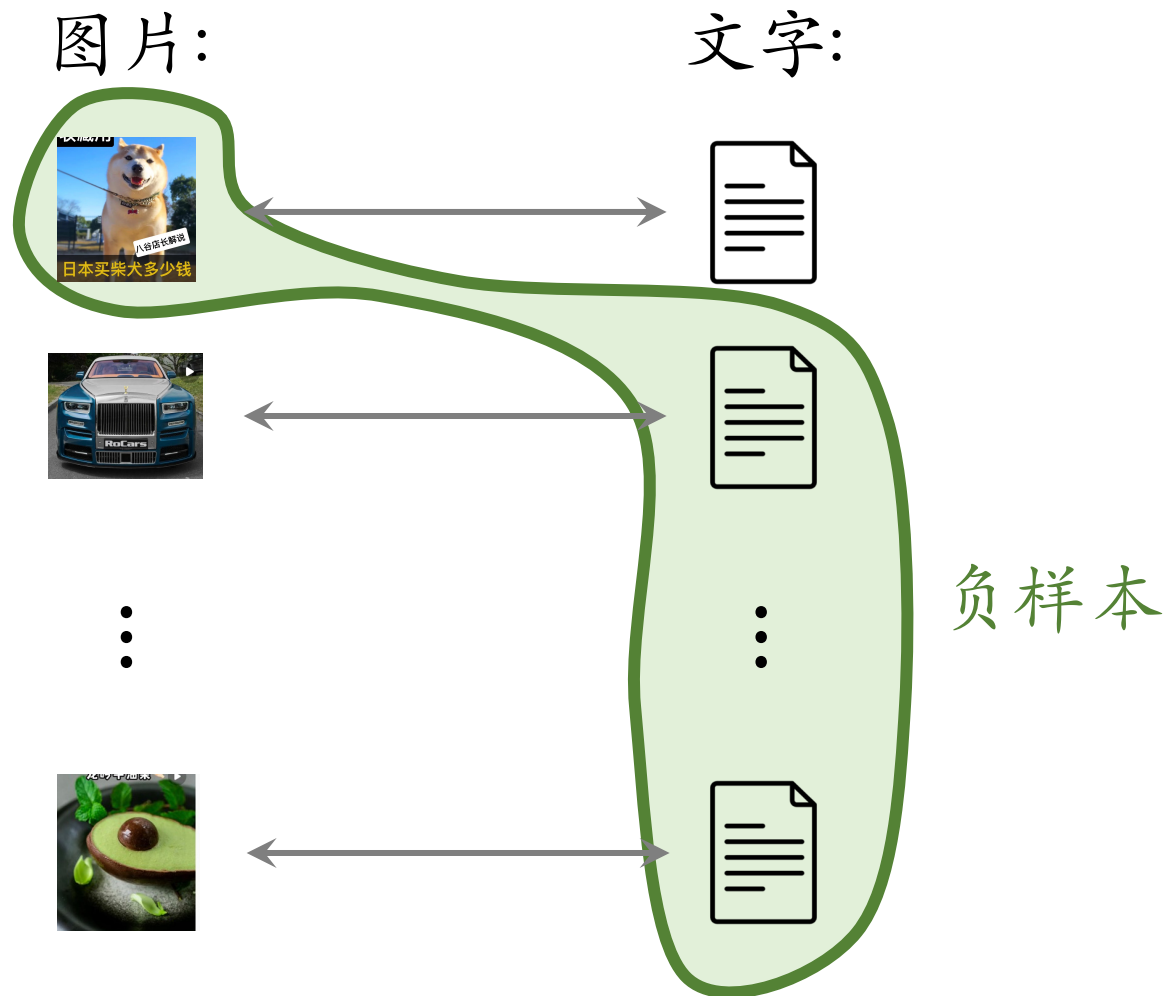
正样本

⋮

⋮




基于图文内容的物品表征



- 一个 batch 内有 m 对正样本。
- 一张图片和 $m - 1$ 条文本组成负样本。
- 这个 batch 内一共有 $m(m - 1)$ 对负样本。


提升多样性的方法

推荐系统的链路




- 粗排和精排用多目标模型对物品做 pointwise 打分。
- 对于物品 i ，模型输出点击率、交互率的预估，融合成分数 reward_i 。
- reward_i 表示用户对物品 i 的兴趣，即物品本身价值。

推荐系统的链路



- 给定 n 个候选物品，排序模型打分
 $\text{reward}_1, \dots, \text{reward}_n$ 。
- 从 n 个候选物品中选出 k 个，既要它们的总分高，也需要它们有多样性。

推荐系统的链路



Thank You!

<http://wangshusen.github.io/>